

MGI

Mestrado em Gestão de Informação

Master Program in Information Management

PEOPLE ANALYTICS APLICADO À RETENÇÃO DE TALENTOS NAS ORGANIZAÇÕES

Maria do Rosário Ligeiro Pinto Canais

Trabalho de Projeto apresentado como requisito parcial para obtenção do grau de Mestre em Gestão de Informação

NOVA Information Management School Instituto Superior de Estatística e Gestão de Informação

Universidade Nova de Lisboa

)15			_							MEGI	
2015	People Analy	ytics aplicado	à Retenção de	Talentos			Maria do Ro	sário Ligeiro F	Pinto Canais	MGI	

People Analytics aplicado à Retenção de Talentos

Maria do Rosário Ligeiro Pinto Canais



NOVA Information Management School Instituto Superior de Estatística e Gestão de Informação

Universidade Nova de Lisboa

PEOPLE ANALYTICS APLICADO À RETENÇÃO DE TALENTOS NAS ORGANIZAÇÕES

1	n	^	ľ
ı	ν	v	ı

Maria do Rosário Ligeiro Pinto Canais

Trabalho de Projeto apresentado como requisito parcial para a obtenção do grau de Mestre em Gestão de Informação

Orientador: Professor Doutor Roberto Henriques

Fevereiro 2016

DEDICATÓRIA

Aos meus filhos, João Manuel e Laura Sofia,

que ao longo destes meses muitas foram as ocasiões em que não tiveram a mãe presente.

Ao meu marido,

que tornou possível a concretização desta aventura.

AGRADECIMENTOS

Ao longo deste trabalho, muitas foram as pessoas que, de uma maneira ou de outra, me acompanharam e às quais gostaria de agradecer.

Pela força sempre amiga, agradeço ao primo João, à tia Júlia e, em especial, à amiga Gisela Fontes, que soube ter as palavras certas nos momentos certos.

Aos colegas e novos amigos, sempre presentes e disponíveis, Andrea Pelizzari, Bruno Vieira e Ivo Figueira, a quem desejo as maiores felicidades.

Aos colegas da empresa, Catarina Paço e Marco Alves, por toda a colaboração prestada e à Mariana Canto e Castro pelo apoio incondicional que deu a este projecto.

À minha equipa, Maria João Farto, Carla Plácido e Patrícia Costa, que asseguraram o normal desenrolar dos trabalhos com todo o profissionalismo, apesar de todos os novos desafios que foram sucedendo ao longo deste período.

Ao Professor André Melo, que ao longo do meu percurso académido, esteve sempre disponível e com uma palavra encorojadora para dar e a quem desejo muitos sucessos no seu projeto académico, pessoal e profissional.

Ao meu orientador, Professor Roberto Henriques, que me acompanhou ao longo deste Trabalho de Projecto apontando os caminhos a seguir, a quem eu desejo igualmente muitos sucessos pessoais e profissionais.

À Catarina Horta, que me lançou neste desafio, a quem o meu agradecimento vai muito para além deste trabalho agora encerrado.

Ao CEO da Randstad Portugal, Eng. José Miguel Leonardo, que me apoiou e incentivou desde o primeiro ao último dia, o meu muito obrigada.

RESUMO

O presente Trabalho de Projeto apresenta o percurso efetuado à volta da temática da Retenção de Talentos apresentando diversas abordagens que passaram pela identificação da relevância do tema nas organizações, pela identificação dos conceitos inerentes e conhecimento de algumas técnicas aplicáveis a modelos preditivos e respetiva replicação em contexto organizacional com vista a evidenciar a efetiva viabilização do *People Analytics* na função Recursos Humanos.

A bibliografia disponível a nível mundial aponta para a necessidade da função Recursos Humanos assumir novos papéis nas organizações e posicionar-se como parceiro estratégico dos CEOs para apoiar de forma eficaz na definição de políticas de Retenção de Talentos.

Tendo como ponto de partida a definição de Talento de Lynne (2005), citada por Jantan, Hamdan, & Othman (2010), que refere que o Talento é a capacidade de uma pessoa em fazer uma diferença significativa no desempenho atual e futuro da organização onde se insere, efetuou-se uma pesquisa alargada para identificação das várias definições que convergem para a sua identificação. Face a vários estudos e publicações disponíveis sobre esta temática foi possível enumerar de forma exaustiva as muitas características que destacam os Talentos nas organizações. Genericamente, as caraterísticas que identificam os Talentos resultam do conjunto de 3 grandes fatores: competências individuais, avaliação de desempenho e *background* do colaborador.

Algumas ferramentas de *People Analytics* disponíveis para a função Recursos Humanos, nomeadamente ferramentas de *Data Mining* e de visualização de dados, foram utilizadas para descrever os Talentos da Organização onde este Trabalho de Projeto foi desenvolvido e prever as classificações dos Talentos no período seguinte.

A viabilidade da utilização de ferramentas de *People Analytics* pela função Recursos Humanos na Retenção de Talentos foi comprovada. No entanto, para mostrar todo o seu potencial, é necessário inverter a atual situação e investir de forma contínua na obtenção de dados em quantidade e qualidade. Atuando desta forma, os Recursos Humanos poderão acompanhar uma das principais tendências mundiais e que é a utilização do *People Analytics* para potenciar o seu papel diferenciador na gestão de recursos humanos em geral e, em particular, na Retenção de Talentos.

PALAVRAS-CHAVE

People Analytics; Retenção de Talentos; High Potential; Modelos Preditivos; Árvores de Decisão; Redes Neuronais

ABSTRACT

This project shows the route made around the theme of Talent Retention presenting various approaches that have gone through the identification of theme relevance in organizations, by identifying the inherent concepts, knowledge of some techniques applicable to predictive models and respective replication in context organization in order to demonstrate the effective viability of the People Analytics in Human Resources function.

The worldwide bibliography available points to the need for the Human Resources function assume new roles in organizations and position themselves as a strategic partner of CEOs to support effectively the definition of Talent Retention policies.

Taking as its starting point the definition of Lynne Talent (2005), cited by Jantan, Hamdan, & Othman (2010), which states that the talent is the ability of a person to make a significant difference in the current and future performance of the organization where it belongs, it was performed an extensive search to identify the various settings that converge for their identification. Faced with a number of studies and publications available on this subject was exhaustively enumerate the many features that highlight the talent in organizations. Generally, the characteristics that identify the Talent is grouped into 3 major factors: individual skills, performance evaluation and background of the employee.

Some People Analytics tools available to the Human Resources function, including tools for data mining and data visualization, was used to describe the Organization's Talent where this Project Work was developed and predict the classifications of the Talents in the following period.

The feasibility of using the People Analytics tools for the Human Resources function in Talent Retention was proven. However, to show its full potential, it is necessary to reverse the current situation and invest continuously in obtaining data in quantity and quality. Acting this way, Human Resources will follow one of the world trends and that is to use the People Analytics to boost its distinctive role in human resource management in general and, in particular, in the Talent Retention.

KEYWORDS

People Analytics; Talent Retention; High Potential; Predictive Models; Decision Trees; Neural Networks

ÍNDICE

1.	Introdução1
	1.1. Enquadramento e relevância do Projeto
	1.2. Objetivos do Projeto3
2.	Revisão da Literatura4
	2.1. A Gestão de Talentos e o People Analytics4
	2.2. O Data Mining aplicado à Gestão de Talentos9
	2.3. Processo Geral para Previsão de Talentos
	2.3.1. Processo de constituição do <i>dataset</i> 13
	2.3.2. Processo de obtenção do modelo preditivo14
	2.3.3.Árvores de Decisão e Redes Neuronais na Retenção de Talentos17
	2.4. Fatores de <i>Performance</i> relacionados com a Retenção de Talentos20
3.	Metodologia31
	3.1. Enquadramento do problema a estudar na Organização31
	3.2. Enquadramento do Processo da Organização Talent Review 201531
	3.2.1. Caracterização do Processo Talent Review31
	3.2.2. Caracterização dos dados e resultados do Talent Review 201533
	3.3. Enquadramento do Processo da Organização GDO
	3.3.1. Caracterização do processo GDO
	3.3.2. Caracterização dos dados e resultados do GDO 2013-201535
	3.4. Metodologia Proposta
	3.5. Constituição dos <i>datasets</i> do Trabalho de Projeto
	3.5.1. Dataset Talent Review 201538
	3.5.2. Dataset GDO 2012-2015
	3.6. Processo preditivo GDO 201642
	3.7. Matriz de Talentos 2016
4.	Resultados e Discussão
	4.1. Apresentação dos resultados obtidos
	4.1.1. Resultados obtidos para o processo GDO 201645
	4.1.2. Previsão dos resultados do <i>Talent Review</i> 201650
5.	Conclusões
6.	Limitações e Recomendações para Trabalhos Futuros56
7.	Bibliografia57
8.	Anexo60
	8.1. Diagrama criado na aplicação SAS Miner 9.3 para modelação preditiva do GDO60

ÍNDICE DE FIGURAS

Figura 2.1 – Componentes do processo da Gestão de Talentos (adaptação de Sadath, 2013) 4
Figura 2.2 - Gestão de Talentos, adaptação de vários autores6
Figura 2.3 – Mapa de indicadores de performance usados em People Analytics (Pease,
Byerly, & Fitz-enz, 2013)8
Figura 2.4 – Exemplos de abordagens a dados em Data Mining adaptado de Berry & Linoff,
(2004)
Figura 2.5 - Processo geral de previsão com utilização de técnicas de Data Mining, adaptado
de Hand (1998)13
Figura 2.6 – Exemplo de representação em Árvore de Decisão da previsão da compra de um computador (Hand, 1998)15
Figura 2.7 – Modelo de funcionamento das Redes Neuronais (Berry & Linoff, 2004)16
Figura 2.8 – Exemplo de funções de ativação das Redes Neuronais, adaptadas de Berry &
Linoff (2004)
Figura 2.9 - Componentes de fatores relacionados com a performance do académico
(adaptado de Jantan, Hamdan, & Othman, 2010)20
Figura 2.10 - Fatores de competências individuais (Jantan, Hamdan, & Othman, 2010) 21
Figura 2.11 - Atributos por fatores de performance em académicos (Jantan, Hamdan, &
Othman, 2009)
Figura 2.12 - Atributos do modelo JDI para identificação de High Potentials (YSC, 2015) 25
Figura 2.13 - Modelo <i>The Essencials of Executive Potential</i> (Fernández-Aráoz, Groysberg, &
Nohria, 2011)25
Figura 3.1 – Matriz de classificação de Talentos da Organização32
Figura 3.2 – Distribuição normal das classificações obtidas via Matriz de Talentos 32
Figura 3.3 – Caracterização do <i>background</i> dos colaboradores internos da Organização 33
Figura 3.4 – Distribuição das classificações dos Talentos da Organização34
Figura 3.5 – Distribuição normal dos resultados do processo GDO na Organização 35
Figura 3.6 Fases da metodologia aplicada à previsão das classificações dos Talentos 201637
Figura 3.7 – Análise das variáveis a integrar o modelo preditivo GDO através do critério
Worth40
Figura 3.8 – Análise das variáveis a integrar o modelo preditivo GDO através do critério
correlação <i>Spearman</i> 41
Figura 3.9 – Análise das variáveis a integrar o modelo preditivo GDO através do critério
Clustering42
Figura 3.10 – Matriz de classificação de Talentos 2016

Figura 4.1 – Visualização dos valores do GDO 2015, GDO 2015 Previsto e GDO 2016	Previsto
	49
Figura 4.2 Observações do Trabalho de Projecto	51
Figura 4.3 – Distribuição dos Colaboradores <i>High Potentials</i> pelas várias Equipas	51
Figura 4.4 – Distribuição das classificações de Talentos 2015-2016	52
Figura 8.1 – Diagrama criado na aplicação SAS Miner 9.3 para modelação preditiva	do GDO
	60

ÍNDICE DE TABELAS

1. INTRODUÇÃO

1.1. ENQUADRAMENTO E RELEVÂNCIA DO PROJETO

Os Responsáveis pelos Departamentos de Recursos Humanos enfrentam hoje desafios num mercado extremamente dinâmico marcado pela inovação tecnológica, escassez de Talento e grandes variações de crescimento entre regiões do globo (BCG, Dezembro 2014).

Segundo a World Federation of People Management Associations e a Boston Consulting Group (2014), para que a função Recursos Humanos seja bem-sucedida face aos desafios a médio prazo e potencie a figura de parceiro estratégico na organização, é necessário priorizar e direcionar o investimento para o desenvolvimento da Gestão de Talentos, da liderança e do *engagement*.

Face às oportunidades e desafios constantes do mercado de trabalho, da tecnologia disponível que potencia o desenvolvimento de novos negócios ou aumento das vantagens competitivas face à concorrência, e todo o *know-how* necessário para responder a novos posicionamentos das empresas, é crucial para um CEO conhecer os Talentos da sua organização com os quais poderá efetivamente contar para a definição e implementação das estratégias da mesma.

Existem várias definições de Talento que convergem para a sua caraterização. Lynne (2005), citada por Jantan, Hamdan, & Othman (2010), refere que o Talento é a capacidade de uma pessoa em fazer uma diferença significativa no desempenho atual e futuro da organização onde se insere.

A Gestão de Talentos, definida como o resultado de assegurar a pessoa certa no emprego certo (Sadath, 2013), tem vindo a desenvolver-se nas organizações através de várias fases com diferentes objetivos e níveis de desenvolvimento atendendo à utilização de ferramentas que potenciam a extração de conhecimento na fase do planeamento estratégico (Tabela 1.1).

Fases da Gestão de Talentos	Objetivos	Nível de Desenvolvimento
Aquisição de Talentos	Identificação de Talentos na fase de recrutamento e seleção	Elevado
Desenvolvimento de Talentos	Desenvolvimento dos colaboradores através de Formação, Coaching, atualização atempada dos conhecimentos específicos da área de atuação da organização, entre outros	Médio
Retenção de Talentos	Mantém os Talentos atualizados e felizes em todos os aspetos, retendo-os na organização	Reduzido

Tabela 1.1 – Nível de desenvolvimento das fases da Gestão de Talentos (Sadath, 2013)

A questão "Quem poderá ajudar-me na definição e implementação das estratégias da organização?" assume uma importância fundamental para qualquer CEO que necessita de reter os seus melhores colaboradores pois serão estes que farão a diferença no desempenho da organização e, consequentemente, contribuirão para a sustentabilidade da mesma. Este tem sido o pensamento de Jeff Bezos, CEO da AMAZON.COM (Fernândez-Aráoz, 2014), empresa de referência ao nível do crescimento, desempenho e estratégia, que repetidamente coloca esta questão de forma a estar constantemente alerta para as necessidades dos seus Talentos e aplicar eficazmente Políticas de Retenção na AMAZON.COM.

A utilização de técnicas como o *Text Mining* para potenciar pesquisas de candidatos através das bases de dados disponíveis na Internet (*Linkedin*, por exemplo), a aplicação do processo de análise *Social Network Analysis* (SNA) para caracterização dos indivíduos a selecionar ou a desenvolver, assim como, ou a utilização de plataformas de *e-learning*, são exemplos do que já é usual aplicar-se nas organizações para adquirir ou desenvolver os seus Talentos.

Já ao nível da *Retenção de Talentos*, há um longo caminho a percorrer pois a função Recursos Humanos encontra-se a passar por uma fase em que lhe é solicitado um contributo maior e com mais impacto no negócio e, ainda assim, poucas organizações têm já implementado de forma ativa o *People Analytics* (o que requer a utilização de tecnologia de *business intelligence* aplicada aos dados sobre pessoas para criação de conhecimento) que colmate as necessidades do negócio (Deloitte, 2015).

O *People Analytics* alia a utilização de tecnologia para processamento de dados na área do *business intelligence* e existência em abundância de dados de pessoas, ferramentas analíticas para melhorar o desempenho da sua função, ou seja, alavancar o seu papel na organização através do *People Analytics*. Para tal, é necessário apostar numa abordagem sistematizada e integrada.

Ao longo deste Trabalho de Projeto irá ser evidenciado como algumas das técnicas de *Data Mining* poderão ser alocadas ao tema da *Retenção de Talentos* e desta forma potenciar a aplicação do crescente desenvolvimento da tecnologia ao nível do processamento de dados e das abordagens ao tratamento de dados em larga escala, no apoio à função Recursos Humanos para alcançar uma das principais tendências para 2015 que é o reinventar da sua forma de trabalhar apostando no *People Analytics* (Deloitte, 2015).

Este tema assume um papel de especial relevância na Organização onde este Trabalho de Projeto foi desenvolvido, tendo um processo definido e implementado com periodicidade anual ao qual apelidou de *Talent Review*. No entanto, este processo é concretizado através das avaliações transmitidas pelas chefias, ficando o output parcialmente dependente da perceção individual dos avaliadores. O Trabalho de Projeto a desenvolver visa atribuir um carácter científico ao processo *Talent Review* na identificação dos seus Talentos com vista ao desenvolvimento de ações estratégicas para a sua retenção na Organização.

Os dados disponibilizados pela Organização resultantes deste processo incluem a caracterização do colaborador sobre se é ou não um *High Potential*, atendendo à definição de ser alguém que supera os resultados dos seus pares de forma consistente, é capaz de avançar uma ou duas etapas em relação à sua posição atual, é um potencial Gestor Sénior a médio/longo prazo. É visto como um modelo a seguir.

Estes e outros dados (classificação de Talentos, desempenho dos colaboradores internos e a sua respetiva caracterização individual) foram disponibilizados para desenvolvimento do modelo preditivo para posterior identificação dos Talentos da Organização.

Com o término do Trabalho de Projeto espera-se proporcionar à função Recursos Humanos da Organização ferramentas de *People Analytics* aplicadas à Retenção de Talentos e informação necessária à definição de políticas eficazes de Retenção de Talentos, reforçando o seu posicionamento estratégico no período atual e futuro.

1.2. OBJETIVOS DO PROJETO

A visão da Organização sobre o seu crescimento sustentado onde este Trabalho de Projeto foi desenvolvido assenta numa estratégia comunicada com total transparência sobre a importância de contar com as melhores pessoas.

Para apoiar a Organização na concretização dessa estratégia, propõe-se com este Trabalho de Projeto alcançar o seguinte objetivo:

Prever as classificações ao nível dos Talentos da Organização através da aplicação de métodos preditivos utilizando os algoritmos Árvores de Decisão e Redes Neuronais, assim como, aplicação de técnicas de visualização de dados para definição de estratégias eficazes à sua retenção.

Para apoiar no alcançar deste objetivo, foi definido um conjunto de objetivos específicos para as etapas percorridas neste Trabalho de Projeto:

- Conhecer a literatura aplicável ao contexto da Retenção de Talentos nas organizações para determinar os atributos relevantes na caracterização de Talentos;
- Identificar as técnicas de Data Mining adequadas ao processamento de dados do processo de Retenção de Talentos e analisar os contextos em que foram aplicadas;
- Constituir uma Base de Dados com informação sobre a avaliação de desempenho dos colaboradores internos da Organização para prever a sua avaliação no período seguinte;
- Com base na avaliação de desempenho e assumindo a manutenção das características individuais dos colaboradores internos, prever as classificações de Talentos da Organização.

2. REVISÃO DA LITERATURA

2.1. A GESTÃO DE TALENTOS E O PEOPLE ANALYTICS

Os Responsáveis pelos Departamentos de Recursos Humanos enfrentam hoje desafios num mercado extremamente dinâmico marcado pela inovação tecnológica, escassez de Talento e grandes variações de crescimento entre regiões do globo (BCG, Dezembro 2014).

Desta forma, o investimento na Gestão de Talentos é uma necessidade premente das organizações e, em particular, para a função Recursos Humanos, tornou-se um dos focos principais de atuação.

A abordagem da função Recursos Humanos ao processo de Gestão de Talentos deverá incluir um conjunto de atividades traduzidas esquematicamente na figura 2.1 e estratégias aplicáveis atendendo às 3 componentes do processo (Sadath, 2013):



Figura 2.1 – Componentes do processo da Gestão de Talentos (adaptação de Sadath, 2013)

Conhecer os colaboradores e os Talentos da organização é, então, responsabilidade fulcral da função Recursos Humanos que, através de uma abordagem estruturada, identifica e desenvolve os Talentos, evitando a saída dos colaboradores, garantindo a atualização permanente de conhecimentos necessários e mantendo-os felizes em todos os aspetos (Sadath, 2013).

No entanto, a identificação dos colaboradores com competência e conhecimentos acima de um padrão definido continua a ser difícil (Pereira, 2015), pelo que, é sugerido que a Gestão de Talentos seja operacionalizada em 3 momentos: definição de Talento, identificação dos *Key Performance Indicators* associados à definição de Talento e monitorização desses indicadores para controlo.

De acordo com Mortan (2005), citada por Jantan, Hamdan, & Othman (2010), um colaborador com Talento tem a capacidade de fazer uma diferença significativa no desempenho atual e futuro da organização onde se insere.

Fernández-Aráoz, Groysberg, & Nohria (2011) enquadram o *Potential* como alguém que estará preparado para assumir papéis de maior responsabilidade dentro da organização. É uma pessoa com a capacidade de crescer e assumir responsabilidades de maior envergadura (um budget maior, uma equipa maior) e de maior abrangência (amplitude e complexidade).

Por outro lado, Ready, Conger, & Linda (2010) definem *High Potentials* como aqueles que conseguem superar de forma consistente e significativa os seus pares em vários assuntos e circunstâncias. A par do elevado nível de desempenho, o seu comportamento reflete a cultura e os valores da empresa de forma exemplar. Para além destes aspetos, os *Higth Potentials*, mostram uma forte capacidade de crescer e de ter sucesso ao longo das suas carreiras dentro da organização de forma mais rápida e eficaz do que os seus pares.

A consultora PriceWahterhouseCoopers (2015) define *High Performers* os colaboradores que possuem uma avaliação de desempenho dentro do *ranking* dos 20% top da organização, enquanto os *High Potentials* são os contribuidores individuais ou colaboradores ao nível da gestão identificados pela organização como tendo potencial de liderança e estão alinhados para evoluírem para um nível de responsabilidade mais sénior.

A Organização onde este Trabalho de Projeto se insere, adotou como definição de *High Potential* alguém que supera os resultados dos seus pares de forma consistente, é capaz de avançar uma ou duas etapas em relação à sua posição atual, é um potencial Gestor Sénior a médio/longo prazo. É visto como um modelo a seguir.

É primordial estabelecer com rigor este enquadramento atendendo à necessidade de estabelecer estratégias de desenvolvimento da organização. Só desta forma, o conjunto de Talentos servirá à organização de forma contínua e é estabelecido um adequado programa de Gestão de *High Potentials*. A dificuldade em atrair *Top Performers* e *High Potentials* foi referida por mais de 60% das 1,600 organizações que participaram no estudo da Towers Watson (2014), assim como, mais de 50% assume dificuldades em retê-los.

A tradicional abordagem da Retenção de Talentos assente unicamente na compensação monetária não é mais suficiente por si só (Mitchell, Holtom, & Lee, 2001). O profundo conhecimento da organização pelos Recursos Humanos é crucial para apoiar a gestão eficaz de recursos e manter os colaboradores felizes e na organização. Tal Ben-Shahar (2015) afirma que as organizações necessitam de investir na felicidade e no bem-estar das suas pessoas para se manterem competitivas. A felicidade é a causa do efeito sucesso. Pessoas com emoções positivas ficam mais criativas, mais motivadas e constroem melhores relações, contribuindo desta forma para melhores resultados da organização.

A motivação pode ser também potenciada através de programas de *coaching*. Esta prática é muito comum em empresas multinacionais, não só no contexto do desenvolvimento de competências e de personalidade, mas também, no âmbito de programas de desenvolvimento e retenção de Talentos (Ariss, 2014).

A figura 2.2 apresenta de forma adaptada diversos vetores enumeradas pela Deloitte (2015), PriceWaterhouseCoopers (2015), Mitchell, Holtom, & Lee (2001) e Ariss (2014) que, atuando de forma concertada e estruturada, contribuem para uma eficaz gestão na área da Retenção de Talentos.



Figura 2.2 - Gestão de Talentos, adaptação de vários autores

Com o desenvolvimento crescente da tecnologia ao nível do processamento de dados na área do business intelligence e existência em abundância de dados de pessoas (big data), tornou-se possível também à função de Recursos Humanos utilizar ferramentas analíticas para melhorar o desempenho da sua função, ou seja, alavancar o seu papel na organização através do *People Analytics*. Para tal, é necessário apostar numa abordagem sistematizada e integrada:

 Utilizando os dados que dispõe sobre os colaboradores resultantes dos seus processos internos de:

Admissão e gestão de colaboradores;

Formação;

Avaliação de desempenho;

Gestão de Talentos;

Processos do Sistema de Gestão da Qualidade;

Processos de negócio.

Otimizando a utilização dos Sistemas de Informação através de:

Aplicações e ferramentas adequadas ao People Analytics;

Utilização de técnicas de *Data Mining* adequadas à extração de informação e conhecimento.

Disponibilizando à Gestão de Topo o seu conhecimento para:

Suporte à tomada de decisão;

Reforçar a posição estratégica da organização;

Sustentar a vantagem competitiva da organização face à concorrência através da gestão e retenção dos seus Talentos.

Fitz-enz & Mattox II (2014) apresentam o *Analytics* como a reunião da arte e da ciência. As artes ensinam a olhar para o mundo; a ciência ensina como fazer algo. Desta forma o *Analytics* proporciona a compreensão sobre as interações e as relações dos elementos de um problema, que vai muito para além da simples utilização da estatística. O *Analytics* é primeiro um quadro mental e, só depois, um conjunto de operações estatísticas.

O *People Analytics* resulta da obtenção de dados de fontes distintas, tais como de pesquisas, de registos e de processos, que permitem criar uma imagem sobre a situação atual e prever situações futuras prováveis. Este termo amplamente utilizado traduz-se simplesmente na compilação inicial de factos objetivos e posteriormente na recolha de dados relacionados. O *People Analytics* apresenta-se dividido em três níveis (Fitz-enz & Mattox II, 2014):

- Descritivo: Revela e descreve as relações entre dados e identifica padrões de comportamento nos dados atuais e históricos. Inclui, por exemplo, dashboards e scorecards, segmentação dos colaboradores da organização, Data Mining para identificação de padrões básicos e relatórios periódicos.
- Preditivo: Utiliza um conjunto variado de técnicas (estatísticas, modelação, Data Mining) através de factos atuais e históricos para realizar previsões sobre o futuro. Trata-se de probabilidades e impacto potencial na organização. Pode envolver, por exemplo, modelos para aumentar a probabilidade de seleção das melhores pessoas, para as desenvolver e para as promover.
- Prescritivo: As análises prescritivas vão para além das previsões e descrevem as opções de decisão e otimização dos colaboradores na organização. É usado para analisar dados complexos para prever resultados, proporcionar opções de decisão e mostrar diferentes impactos no negócio. Envolve, por exemplo, modelos para conhecer os impactos na rentabilidade do negócio resultantes de diferentes investimentos feitos em formação.

A função Recursos Humanos ao acompanhar as tendências do *People Analytics* aplicadas à Gestão de Talento contribui também desta forma, para uma organização mais avançada ao construir e aperfeiçoar abordagens de *data governance*, ao obter dados de comparação com ferramentas analíticas e ao adotar medidas a partir de dados preditivos (PriceWaterhouseCoopers, 2015).

O que medir na área dos Recursos Humanos deve ser, em primeira instância, alinhado com os *stakeholders* das organizações para assim haver um compromisso de alocação de recursos (financeiros e humanos). Sugestões de indicadores de *performance* para potenciar o uso do *People Analytics* foram já enumerados por Pease, Byerly, & Fitz-enz (2013) (figura 2.3).




Figura 2.3 – Mapa de indicadores de performance usados em *People Analytics* (Pease, Byerly, & Fitz-enz, 2013)

Apesar de constatar a lenta capacidade de tirar proveito do potencial analítico envolvido, a Delloitte University Press (2015) aponta, entre outras, a necessidade de serem feitos investimentos para alavancar a utilização de dados na tomada de decisão e potenciar a mudança de funcionamento dos Recursos Humanos nas organizações.

Este desafio pode ser gerido através da utilização de várias ferramentas, entre elas, *Social Network, Key Performance Indicators*, técnicas de *Data Mining*, entre outras. Vários exemplos de empresas que já recorrem à utilização de *People Analytics* são apontadas por Davenport, Harris, & Shapiro, (2010):

Fatores de Recursos Humanos

Monitorização do *engagement* dos colaboradores da **JetBlue** e previsão da performance financeira;

Análise de RH

Identificação das áreas que necessitam de medidas de melhoria na **Lockheed Martin** através de sistemas automáticos de *performance on time*;

Análise de Investimento em Capital Humano

Monitorização dos níveis de satisfação na **Sysco** com impacto significativo no aumento do rácio de retenção e diminuição do custo de processos de recrutamento e de formação;

Previsão da Força de Vendas

Previsão das necessidades futuras de Recursos Humanos para cada unidade de negócio da **Dow Chemical** adaptando o seu modelo às tendências da indústria, políticas ou alterações legais para os vários cenários;

■ Modelo "Valor de Talento"

Utilização de dados de performance dos colaboradores da **Google** para identificação dos fatores que influenciavam a decisão dos seus colaboradores em se manterem ou saírem da empresa através da confirmação de que muitos estavam mal alocados ou tinham uma má gestão direta;

Cadeia de Fornecimento de Talento

Utilização de ferramentas analíticas pelas empresas de retalho para dimensionar adequadamente o número de pessoas necessário face ao volume de vendas previsto.

A função Recursos Humanos para se iniciar na utilização do *People Analytics* deverá implementar a estratégia apresentada pela Deloitte (2015) que aborda os seguintes passos:

- Constituir a equipa certa e mostrar o retorno sobre o investimento;
- Iniciar com as ferramentas disponíveis;
- Envolver o IT como parceiro;
- Utilizar o analytics nos Recursos Humanos para mostrar o seu potencial;
- Incidir o focus nas necessidades imediatas do negócio;
- Alavancar o analytics atualizando plataformas tecnológicas.

2.2. O DATA MINING APLICADO À GESTÃO DE TALENTOS

No desenrolar da normal atividade das organizações através da implementação dos seus processos, assiste-se à produção de dados de forma automática e em enormes quantidades que são armazenados nas bases de dados dos seus sistemas. Estes dados aportam conhecimento quando utilizados métodos de *Data Mining* para a exploração e identificação de padrões de comportamento que sustentam o desenvolvimento de modelos matemáticos descritivos com aplicação em termos de planeamento (Jantan, Hamdan, & Othman, 2009). Os dados disponíveis na organização gerados pelo normal funcionamento desta e utilizados para criação desse conhecimento, chamam-se dados secundários, por oposição aos dados primários utilizados no campo da estatística (Bação, 2013).

Os modelos resultantes da aplicação de métodos de *Data Mining* apresentam decisões inteligentes equivalentes às decisões tomadas por humanos. No entanto, a rapidez das decisões inteligentes derivada da forma automática como surgem apresentam vantagens significativas quando comparadas com as decisões por partes dos humanos. Estas são mais demoradas, com algumas incertezas e dependentes de vários fatores como experiência, conhecimento, preferências e julgamentos de quem tem a responsabilidade de decidir (Jantan, Hamdan, & Othman, 2010).

A abordagem aos dados permite a divisão dos modelos em 3 grandes tipos, aos quais estão associados os métodos a aplicar. Os métodos descritivos e preditivos de *Data Mining* do tipo *machine learning* assentam na análise dos dados utilizando algoritmos que aprendem interactivamente a partir destes, fazendo com que os computadores encontrem conhecimento oculto sem serem explicitamente programados para encontrarem algo. Alguns desses exemplos mais conhecidos encontram-se na figura 2.4 (Jantan, Hamdan, & Othman, 2010):




Figura 2.4 – Exemplos de abordagens a dados em Data Mining adaptado de Berry & Linoff, (2004)

A técnicas de *Data Mining* utilizam-se no mais variado leque de campos de aplicação por serem consideradas bastante adequadas ao desenvolvimento de modelos descritivos e preditivos, conforme comprovado pelos inúmeros estudos já realizados. As atividades mais comuns em *Data Mining* dividem-se em (Berry & Linoff, 2004):

Modelação Descritiva

Clustering

- Regras de associação
- Link analysis
- Visualização

Modelação Preditiva

- Classificação (variáveis de classes)
- Regressão (variáveis contínuas)

Também na área dos Recursos Humanos e, mais recentemente, com as novas responsabilidades e visibilidade desta função nas organizações, o seu papel estratégico é potenciado ao utilizar métodos de *Data Mining* (Jantan, Hamdan, & Othman, 2010).

A Gestão de Talentos é hoje um dos maiores desafios desta era de mobilidade global e motivação para abarcar novos desafios principalmente nas gerações mais jovens (D'Amato & Herzfeldt, 2008). A utilização de métodos de *Data Mining* permitirá caracterizar e acelerar a previsão de comportamentos tornando assim a função Recursos Humanos mais eficiente.

Apesar de não existirem muitos estudos disponíveis na área dos Recursos Humanos que evidenciem a utilização de métodos de *Data Mining* e, em particular, na área da Gestão de Talentos, os que existem convergem para as temáticas em análise.

No estudo levado a cabo por Jantan, Handan, & Othman (2009), são apresentadas as atividades de seleção de novos colaboradores, *matching* dos colaboradores às funções que desempenham, desenvolvimento de planos de carreira e de planos de formação face às necessidades diagnosticadas para os novos e/ou colaboradores antigos, previsão do desempenho atual do colaborador, previsão do colaborador na empresa, etc., como temas possíveis de abordar através de técnicas de *Data Mining* (tabela 2.1).

Data Mining	Atividade dos Recursos Humanos
Árvores de Decisão	Seleção de candidatos Desenvolvimento de colaboradores Comportamentos dos colaboradores
Rough Set Theory	Seleção de candidatos Retenção de Talentos
Fuzzy Data Mining	Seleção de candidatos Desenvolvimento de colaboradores Comportamentos dos Colaboradores Alocação de gestão de projetos
Regras de Associação	Desenvolvimento de colaboradores Formação
Redes Neuronais	Desenvolvimento de colaboradores Alocação de gestão de projetos

Tabela 2.1 - Técnicas de Data Mining aplicadas aos RH (Jantan, Hamdan, & Othman, 2009)

Esta tabela expõe a fraca utilização da aplicação das técnicas de *Data Mining* no domínio dos Recursos Humanos. Recentemente, assiste-se a um crescendo na inversão desta caracterização potenciada pela difusão do seu potencial nas revistas, *sites* e fóruns de Recursos Humanos, mas principalmente focado na área da seleção. Este facto poderá ser explicado pela facilidade de constituição de bases de dados com os atributos relevantes na fase da seleção (habilitações literárias, formações complementares, experiência, atividades extraprofissionais, entre outros) agilizada pela inserção dos dados pelos próprios candidatos através do *site* das organizações ou utilizando ferramentas universalmente disponíveis como é, por exemplo, o site *Linkedin*.

Para além dos dados de candidatos, também os dos colaboradores e potenciais empresas contratantes estão largamente disponíveis na Internet pelo que deverão ser usados pelas empresas para identificar os melhores candidatos, compreender o nível de *engagement* do colaborador, prever e reduzir o risco da sua saída da organização (Deloitte, 2015).

A seleção das técnicas de *Data Mining* para a Gestão de Talentos passa pelo conhecimento das características respetivas apresentadas por Berry & Linoff (2004), Hand (1998) e Jantan, Handan, & Othman (2009) e resumidas na tabela 2.2:

Técnicas de Data Mining	Características				
Redes Neuronais (Berry & Linoff, 2004)	 Adequada para estudos de clustering, classificação e previsão Aprende com padrões de exemplo Aproximação à função Algoritmo adequado perante dados com alguma complexidade 				
Árvores de Decisão (Hand, 1998)	 Adequada para classificação e previsão Aplicável a variáveis contínuas e de classes Produz um modelo que representa regras interpretáveis fáceis de explicar aos decisores Não exige conhecimentos específicos Não exige definição de parâmetros iniciais Capaz de lidar com muitos dados Produz modelos com boa accuracy Capaz de lidar com dados com ruído 				
Rought Set Theory Jantan, Handan, & Othman (2009)	 Pode explicar e explorar o modo como a decisão foi tomada com regras simples, compreensíveis e úteis na presença ou incerteza e indefinição da informação 				
Fuzzy Clustering Jantan, Handan, & Othman (2009)	 Mais geral do que os métodos convencionais Usado na construção de relações entre os dados Usado na transformação de relações em conhecimento 				
Support Vector Machine (SVM) Jantan, Handan, & Othman (2009)	 Pode ser usado para previsão, assim como, para classificação Fornece uma descrição compacta do modelo aprendido É bastante preciso 				

Tabela 2.2 - Técnicas de *Data Mining* com potencialidade na Gestão de Talentos (vários autores)

2.3. PROCESSO GERAL PARA PREVISÃO DE TALENTOS

O processo geral para previsão aplicado a qualquer área em estudo através da utilização de técnicas de *Data Mining* agrega um conjunto de tarefas com vista a garantir a adequada qualidade do modelo selecionado. A aplicação de técnicas de previsão é utilizada quando se conhece a variável *target* (aprendizagem supervisionada ou *supervised learning*) através da criação de modelos paramétricos (Berry & Linoff, 2004).

Esquematicamente, as tarefas podem ser agregadas em subgrupos que constituem vários subprocessos que se interligam entre si, conforme exposto na figura 2.5 adaptada de Hand (1998):




Figura 2.5 - Processo geral de previsão com utilização de técnicas de *Data Mining, adaptado de* Hand (1998)

2.3.1. Processo de constituição do dataset

No processo de constituição do *dataset*, deve-se atender à identificação das variáveis a constituir a base de dados que sejam representativas da caracterização do problema em estudo e à quantidade de exemplos necessários para a obtenção das regras do modelo com qualidade.

A preparação dos dados requer atenção do analista em diversos temas que caracterizam a obtenção de dados dispersos em bases de dados que suportam os sistemas das organizações com vista a garantir a sua adequabilidade à aplicação de técnicas de *Data Mining*. Se necessário, devem ser atendidas e resolvidas questões como a existência de dados errados, *outliers*, valores não numéricos, valores omissos e necessidade de aplicação de filtros (Hand, 1998).

A tarefa de pré-processamento dos dados tem um papel muito importante na qualidade final do modelo. A existência de muitas variáveis que caracterizam o problema em estudo promove uma representação espacial esparsa, requerendo a existência de muitos dados (padrões de exemplo) nos

dados de treino para identificação de padrões de comportamento que permitam ao modelo aprender como as variáveis (*inputs*) se relacionam entre si. Esta situação pode levar ao aparecimento do fenómeno *Maldição da Dimensionalidade*, por influenciar negativamente a obtenção de um modelo matemático com a complexidade e qualidade necessárias para a obtenção de regras com a menor taxa de erro. A redução do espaço de *input* é assim crucial sendo a redução do número de variáveis possível através da seleção das que têm maior capacidade discriminativa preterindo as que possuem uma relação espúria entre *input/output*, identificação das variáveis correlacionadas, redundantes e irrelevantes, aplicação de médias ou de outras medidas estatísticas, efetuando análise das componentes principais (ACP), etc. A normalização dos dados para uma representação espacial em escalas equivalentes, assim como, a criação de novas variáveis (criação de indicadores através de rácios com variáveis existentes) que resultam do *know-how* do analista sobre o problema em estudo, contribuem igualmente para garantir um adequado *dataset* a utilizar no processo de *Data Mining* (Hand, 1998).

2.3.2. Processo de obtenção do modelo preditivo

No processo de aprendizagem, e face à disponibilidade de várias técnicas possíveis para aplicar na Retenção de Talentos, é recomendável a utilização de mais do que uma técnica para posterior avaliação e comparação dos respetivos modelos permitindo assim, a obtenção de um modelo preditivo com maior accuracy (Jantan, Hamdan, & Othman 2010).

Neste Trabalho de Projeto irão ser utilizadas Árvores de Decisão e Redes Neuronais para a obtenção do modelo preditivo adequado à Retenção de Talentos da Organização.

Árvores de Decisão

As Árvores de Decisão são um método não paramétrico que divide consecutivamente um conjunto alargado de dados em subconjuntos aplicando regras simples que promovem a homogeneidade destes atendendo a determinada variável *target* (Berry & Linoff, 2004).

Hand (1998) apresenta as Árvores de Decisão como uma representação gráfica onde:

- Cada nó representa um teste ao atributo;
- Cada ramo representa a resposta ao teste;
- Cada nó terminal representa um conjunto homogéneo de dados

em que um exemplo simples poderá ser o observado na figura 2.6:




Figura 2.6 – Exemplo de representação em Árvore de Decisão da previsão da compra de um computador (Hand, 1998)

Os primeiros algoritmos apresentados, o ID3 (*Iteractive Dichotomiser*) e o C.4.5 (sucessor do ID3), desenvolvidos pelo investigador em *machine learning* Ross Quinlan, e o algoritmo CART (*Classification and Regression Tree*) desenvolvido pelo grupo de estatísticos Braiman, Friedman, Olshen and Stone nas décadas de 70 e 80, de forma independente, alavancou a visibilidade das Árvores de Decisão no mundo científico (Hand, 1998).

As Árvores de Decisão assentam numa abordagem de *top-down* para seleção dos atributos que constituem as regras do modelo, com sucessiva divisão do *dataset* de treino até formar grupos com características homogéneas (Hand, 1998).

Este procedimento implica a utilização de medidas adequadas à **seleção dos atributos** com maior capacidade descriminante.

Hand (1998) apresenta que, da aplicação das medidas de seleção de atributos adequada, o critério de divisão de cada nó da árvore em novos ramos (*subsets*) identifica:

- O melhor atributo a partir do qual deve ser feita a divisão em cada nó
- Os ramos que devem crescer do nó face ao objetivo em estudo

A divisão sucessiva dos vários *subsets* cessa quando os terminais do grafo (equivalente à imagem das folhas de uma árvore) apresentam grupos de classes o mais homogéneos possível. A existência de uma única classe nos *subsets* finais representará o grau de pureza ideal pretendido no exercício.

Redes Neuronais

As Redes Neuronais são modelos de *supervising learning* baseados na analogia com a interação anatómica entre os neurónios do cérebro, na forma como se comportam entre si e como são ativados para produzirem determinado resultado.

As Redes Neuronais representam um método prático de aprendizagem através de dados de treino conferindo uma robustez nos resultados sendo, por esta razão, um dos métodos preditivos amplamente utilizado em diversos campos de aplicação (Berry & Linoff, 2004).

A curiosidade pelo funcionamento das redes neuronais do ser humano (neutrões biológicos), inspirou Warren McCulloch, neuro fisiologista da Universidade de Yale, e Walter Pitts, especialista em lógica, a realizarem e documentarem em 1943 um estudo intitulado "A Logical Calculus Immanent in Nervous Activity". Apesar do estudo incidir sobre a compreensão da anatomia do cérebro, o modelo apresentado rapidamente se tornou uma inspiração no campo da inteligência artificial para resolução de problemas fora do contexto da neurobiologia (Berry & Linoff, 2004).

Num modelo teórico de Redes Neuronais têm-se as seguintes equivalências (figura 2.7):

Neurónios: dados de input

<u>Interação entre os neurónios</u>: determinada pelos Pesos/*Weights* e parâmetro *Bias* usado para controlar as fronteiras à volta da origem da função

Resultado: ativação de uma função estatística para obtenção do output




Figura 2.7 – Modelo de funcionamento das Redes Neuronais (Berry & Linoff, 2004)

A função de ativação promove um efeito de "squashing" nos elementos de ativação (z) o que se traduz numa melhoria dos cálculos numéricos preservando a ordem dos dados.

A figura 2.8 apresenta as funções estatísticas que se podem aplicar no modelo.




Figura 2.8 – Exemplo de funções de ativação das Redes Neuronais, adaptadas de Berry & Linoff (2004)

A apresentação de *dados de teste* ao modelo obtido permite avaliar a qualidade do mesmo através do erro obtido associado à complexidade do polinómio do modelo, que deverá ser selecionada para o menor valor do erro encontrado. Esta tarefa permite contornar o fenómeno indesejável da sobreaprendizagem ou *overfitting*, que poderá ocorrer com o conjunto de dados de treino do modelo. A utilização de dados diferentes para treino, validação e teste do modelo para contorno do fenómeno do *overfitting* denomina-se de *cross-validation* (Bação, 2013).

2.3.3. Árvores de Decisão e Redes Neuronais na Retenção de Talentos

No estudo que Jantan, Hamdan, & Othman (2010) desenvolveram sobre a população de académicos (Professor; Professor Associado; Professor Sénior; Professor) de várias instituições da Malásia, tiveram como objetivo validar a aplicabilidade das Árvores de Decisão e das Redes Neuronais na obtenção de modelos de previsão adequado à área da Retenção de Talentos através da identificação dos respetivos valores de *accuracy*.

Para os atributos considerados adequados aos académicos e utilizando como variável target a questão "recomenda a promoção do académico?", Jantan, Hamdan, & Othman (2010) constituíram um conjunto de datasets que utilizaram para criar os dados de treino e os dados de teste. Estes dados foram, na sua maioria, gerados aleatoriamente por se considerar informação confidencial os dados dos académicos. Através da utilização das ferramentas WEKA e ROSETTA, aplicaram o processo geral de Data Mining para classificação e previsão dos Talentos académicos tendo obtido os seguintes valores de accuracy (tabela 2.3):

Accuracy dos modelos de classificação e previsão

Estudo A, Fase 1 – Todos os Atributos

- Simulação, preparação e pré-processamento de dados para 53 atributos
- Inserção dos outliers no dataset1 (dataset 3)

Algoritmos		Dataset 1	Dataset 2	Dataset 3	
		#100	#200	#100	
Árvores Decisão	C4.5	95,14	99,90	90,54	
	Random Forest	74,91	95,43	71,80	
Redes Neuronais	MLP	87,16	99,84	84,55	
	RBFN	91,45	99,98	87,09	
Clustering	K-Star	92,06	97,83	87,79	

Estudo A, Fase 2 – Redução de Atributos

- Redução de atributos através do método de raciocínio booleano
- Seleção dos atributos com menor comprimento
- Combinação com os atributos mais importantes

Algoritmos		Dataset	Dataset	Dataset	Dataset
		RAtrb1 #100	RAtrb2 #200	Almp1 #100	Almp2 #200
Árvores Decisão	C4.5	61,06	63,21	95,63	99,89
	Random Forest	58,85	62,49	86,50	99,88
Redes Neuronais	MLP	55,32	60,16	79,49	99,91
	RBFN	59,52	64,05	84,41	99,96
Clustering	K-Star	60,22	63,92	78,40	99,95

Estudo B – Todos os Atributos

- Simulação, preparação e pré-processamento de dados para 17 atributos
- Recolha de dados reais e preparação de dados para 17 atributos

Algoritmos		Dataset 1	Dataset 2	Dataset 3	Dataset 4	Dataset 5
		(Simul) #199	(Real) #295	(Real) #135	(Real) #160	(Real) #295
Árvores Decisão	C4.5	97,44	58,95	54,43	57,52	57,90
	Random Forest	95,31	58,95	53,79	58,03	56,88
Redes Neuronais	MLP	92,28	58,24	52,36	59,00	56,16
	RBFN	92,30	61,91	54,40	63,31	56,23
Clustering	K-Star	71,81	48,00	47,31	51,73	47,24

número de observações

Tabela 2.3 - Modelos de classificação e previsão com atributos de académicos (Jantan, Hamdan, & Othman, 2010)

Dos estudos apresentados, as conclusões mais relevantes são:

- Datasets com maior número de dados (disponibilizam mais padrões de exemplo) permitem a construção de modelos de classificação com melhores valores de accuracy;
- Utilizando datasets com dados simulados, obtêm-se modelos de classificação com uma accuracy superior face aos dos modelos com dados reais;
- A presença de outliers durante o processo de aprendizagem origina modelos de classificação com piores valores de accuracy;
- A preparação dos dados tem um impacto significativo na accuracy do modelo quando se utilizam datasets com dados reais;
- A utilização indiscriminada de todos os atributos disponíveis no dataset pode comprometer a accuracy do modelo de classificação;
- A redução do número de atributos pode reduzir a accuracy do modelo de classificação, quando selecionados sem um critério adequado;
- A redução do número de atributos combinada com a identificação dos mais importantes melhora significativamente a accuracy dos modelos de classificação.

2.4. FATORES DE PERFORMANCE RELACIONADOS COM A RETENÇÃO DE TALENTOS

A abordagem a um problema de *Data Mining* inicia-se por uma clara e inequívoca caracterização do problema a estudar, cujo impacto se irá refletir na constituição do *dataset* a utilizar para obtenção do modelo preditivo.

No tema em causa, Retenção de Talentos, passa por ter inicialmente a clara perceção do:

- Definição de Talento ou termo equivalente;
- Objetivo da aplicação do conhecimento;
- Caracterização exaustiva dos fatores que compõem a definição de Talento e/ou termo equivalente.

No âmbito deste projeto, serão tidas como referências as seguintes definições:

Talento, capacidade de uma pessoa em fazer uma diferença significativa no desempenho atual e futuro da organização onde se insere de acordo com Lynne (2005), citada por Jantan, Hamdan, & Othman, (2010).

High Potential, alguém que supera os resultados dos seus pares de forma consistente, é capaz de avançar uma ou duas etapas em relação à sua posição atual, é um potencial Gestor Sénior a médio/longo prazo. É visto como um modelo a seguir (definição utilizada na Organização onde o Trabalho de Projeto foi desenvolvido).

Sendo o objetivo da implementação deste Trabalho de Projeto a atuação sobre a fase da Retenção de Talentos, o *focus* da seleção das variáveis que irão constituir a Base de Dados é orientado para o histórico do colaborador ao longo do seu percurso profissional *dentro da organização*.

Esta abordagem é muito importante, pois é a partir destes dois enquadramentos, que irá ser possível identificar os comportamentos e resultados esperados dos colaboradores e que permitirão o estabelecimento de regras eficazes que classificam os Talentos/*High Potentials* numa organização.

Para identificar estes comportamentos, Jantan, Hamdan, & Othman (2009, 2010) realizaram alguns estudos recorrendo a técnicas de *Data Mining* e abordando a temática da Retenção de Talentos. Para tal, utilizaram dados de uma população de académicos de várias instituições da Malásia, em que estruturaram todo o processo com o objetivo de conseguirem prever a *performance* dos académicos através da resposta à pergunta: *recomenda a promoção do académico?*

Jantan, Hamdan, & Othman (2010), apresentam 3 componentes de fatores relacionados com a *performance* do académico (figura 2.9):



Figura 2.9 - Componentes de fatores relacionados com a *performance* do académico (adaptado de Jantan, Hamdan, & Othman, 2010)

Para a população de académicos em análise (Professor; Professor Associado; Professor Sénior; Professor), assim como, para as responsabilidades e atividades desenvolvidas, foram considerados os fatores de competências individuais expostos na figura 2.10 (Jantan, Hamdan, & Othman, 2010):




Figura 2.10 - Fatores de competências individuais (Jantan, Hamdan, & Othman, 2010)

No contexto genérico e para o fator "Conhecimento e *skills*" identificaram a necessidade de avaliar os conhecimentos necessários para a função, assim como, a capacidade para identificação, análise e resolução de problemas. A realização de tarefas de acordo com procedimentos da organização e a existência de *skills* de comunicação são também atributos relevantes a atender na avaliação da performance do indivíduo.

As "Características Pessoais" concentram um conjunto variado de competências quer ao nível da caracterização individual, quer na forma como o indivíduo se relaciona com o meio envolvente. Os indivíduos com maior performance destacam-se ao nível das competências de liderança, organização, disciplina, pro-atividade e inovação, assim como, estabelece com facilidade relações e cooperação dentro da organização.

Para o fator "Resultado de Trabalho realizado" identificaram a necessidade de avaliar a quantidade e a qualidade de trabalho realizado, atendendo ao tempo consumido e eficácia do cumprimento dos requisitos estipulados enquanto a colaboração ativa em atividades várias com a organização e/ou comunidade complementam as diferentes variáveis que contribuem para a avaliação do indivíduo.

Exemplificando para o contexto dos académicos, Jantan, Hamdan, & Othman (2009) identificaram esquematicamente que os atributos com impacto na sua *performance* são os apresentados no esquema da figura 2.11:




Figura 2.11 - Atributos por fatores de performance em académicos (Jantan, Hamdan, & Othman, 2009)

A lista dos atributos e variáveis de *input* para as componentes de fatores relacionados com a *performance* dos académicos apurados por Jantan, Hamdan, & Othman (2010) e que serviram de suporte à constituição do *dataset* para os diversos estudos efectuados encontram-se listados na tabela 2.4:

Fatores e atributos relacionados com a <i>performance</i> do académico	Variáveis de input	
Background	Idade, raça, género,	
	Ano de admissão, ano de promoção 1,2 e 3	
Avaliação de Desempenho	Avaliação de desempenho ano 1, 2,,15	
Conhecimento e Skills (Q1)	Horas de ensino, número de supervisões,	
	Número de pesquisas, número de conferências,	
	Número de publicações em jornais nacionais e	
	internacionais,	
	Número de procedimentos publicados a nível nacional e internacional	
Skills de Gestão (Q1)	Número de participações como gestor de projetos	
Atividades e Contribuição (Q2)	Tarefas administrativas	
Qualidades Individuais (Q3)	Formação, valorização	
	Número de prémios de pesquisa	
	Número de prémios de serviço	

Tabela 2.4 - Fatores, atributos e variáveis a atender na Retenção de Talentos em académicos Jantan, Hamdan, & Othman (2010)

O estudo apresentado é específico da população "académicos". Com vista ao enriquecimento da identificação de fatores e atributos a ter em consideração no contexto da Retenção de Talentos nos indivíduos em geral, outros estudos e modelos desenvolvidos por *experts* serão apresentados de seguida.

O estudo levado a cabo por D'Amato & Herzfeldt (2008) visou identificar a possível relação entre a variável *Idade* e com a Retenção da Talentos baseada na indicação da intenção dos colaboradores em *desenvolverem competências através da formação* e, desta forma, potenciar a identificação de Planos de Desenvolvimento e Planos de Retenção eficazes.

Tratou-se de uma autoavaliação de 1,666 gestores europeus de diferentes faixas etárias durante 2006 e 2007, através da resposta a um questionário anónimo com questões organizadas em 3 fatores diferentes (tabela 2.5) e incluíam a indicação do gestor sobre a sua *intenção de se manter na organização nos próximos 3 anos*:

Fator Aprendizagem Orientada	Fator Desenvolvimento de Competências de Liderança	Fator Comprometimento Organizacional
Orientação para aprendizagem no trabalho: No presente; Para o futuro.	Motivação para o desenvolvimento de competências de liderança através de formação: Competências Sociais: Avaliação de desempenho; Contratação / entrevistas; Gestão do tempo; Resolução de problemas; Espírito de equipa; Qualidade / melhoria de processos; Comunicação em público; Apresentações. Facilitação do trabalho Gestão empresarial; Visão estratégica; Planeamento estratégico; Gestão da mudança; Coaching; Política no trabalho.	Orientação de compromisso para com a organização através do envolvimento: Em operações atuais; Em operações futuras.

Tabela 2.5 - Fatores de Retenção de Talentos atendidos no estudo com gestores europeus

Este estudo utilizou testes de hipóteses tendo apresentado como resultados que a *Formação* e a *Idade* são atributos a ter em consideração no estabelecimento de Planos de Desenvolvimento e de Retenção de Talentos devido às características opostas encontradas nas faixas etárias estudadas:

- As faixas etárias mais velhas estão menos recetivas ao desenvolvimento de competências através da Formação a par da manifestação da sua intenção em se manterem na organização nos próximos 3 anos;
- As faixas etárias mais novas estão mais disponíveis para aceitar desafios fora da organização para desenvolvimento e valorização da sua carreira profissional aceitando, de bom grado, as oportunidades de formação que lhes possam ser proporcionadas.

Também Nuno Troni (2015) identifica no retrato profissional da geração nascida após 1980 comportamentos específicos para estas faixas etárias. O *feedback* contínuo sobre o seu desempenho é bastante apreciado no sentido de ser percecionado como motor no desenvolvimento individual. Desta forma, os processos de avaliação de desempenho que preveem vários momentos de *feedback* ao longo do ano, a par de momentos menos formais, deverão ser potenciados e implementados pelas organizações como formas eficazes de políticas de Retenção de Talentos, com especial impacto positivo nas gerações mais novas.

O relatório "Global Human Capital Trends 2015" da Deloitte (2015) vem corroborar na importância de atender ao fator idade nas estratégias a aplicar na Retenção de Talentos. No mercado de trabalho atual, caracterizado pela elevada dinâmica e transparência, constata-se que a geração mais nova de High Potentials pretende ser gerida com regular feedback e orientação sobre a sua progressão de carreira, ao invés da tradicional revisão anual.

Face a estas constatações, a componente do *Background* (caracterização do indivíduo) no conjunto dos fatores relacionados com a *performance* do colaborador, é assim sugerida como relevante para ter em consideração na construção do modelo preditivo na temática da *Retenção de Talentos*.

Por outro lado, *expertises* na área da gestão de Recursos Humanos, ao longo de várias de investigação, foram desenvolvendo modelos para identificação de *High Potentials* como ferramentas de apoio às organizações para otimizarem o seu desenvolvimento e crescimento. O modelo *JDI, Judgement, Drive e Influence* assenta em torno dos conceitos de *Capacidade de Análise, Motivação* e *Influência* e foi desenvolvido ao longo de cerca de 2 décadas utilizando dados e conhecimento do perfil psicológico com a participação de mais de 20.000 psicólogos seniores em todo o mundo (YSC, 2015).

Os psicólogos que desenvolveram o modelo acreditam que os indivíduos com potencial têm um padrão muito próprio de motivação individual, *skills* cognitivos e abordagens específicas para lidar com o mundo social (YSC, 2015).

A abordagem tradicional sobre o *Potential* foca-se na facilidade de aprendizagem do indivíduo; o modelo *JDI*, vai para além desta abordagem, ao procurar encontrar as qualidades que permitem ao indivíduo não só adaptar-se às necessidades emergentes como também distinguir-se pelo impacto único que cria no ambiente onde se insere. Os atributos usados no modelo *JDI* para identificação de *High Potentials* encontram-se esquematizados na figura 2.12 (YSC, 2015):



Figura 2.12 - Atributos do modelo JDI para identificação de High Potentials (YSC, 2015)

Já o modelo *The Essentials of Executive Potential* desenvolvido pela Egon Zehnder International e apresentado por Fernández-Aráoz, Groysberg, & Nohria (2011) assenta em 5 elementos diferentes segregados pelo grau de dificuldade do indivíduo em concretizar a mudança em si próprio (figura 2.13).




Figura 2.13 - Modelo The Essencials of Executive Potential (Fernández-Aráoz, Groysberg, & Nohria, 2011)

Os 3 fatores apresentados como mais difíceis de mudar ou de adquirir (*Motivos Individuais, Liderança* e *Identidade de Executivo Sénior*) são identificados pelos autores do artigo como os essenciais na identificação de *High Potentials*.

Os fatores *Motivos Individuais* relacionam padrões de comportamento consistentes ao longo do tempo e identificam a sua forma de ser e de estar na organização através dos atributos:

- Influenciadores positivos
- Estáveis

- Energizer/Contagia com energia positiva
- Engagement/Envolvidos com a organização

Por outro lado, as competências de *Liderança* identificam o quão irá longe o seu crescimento e a que velocidade atendendo a 4 atributos:

- Visão para transformar informação em novas ideias
- Capacidade para envolver outras pessoas
- Capacidade de resolução
- Procura de conhecimento

A *Identidade de Executivo Sénior* não movida pelo prestígio mas pela consciência em querer contribuir de forma diferente na organização é outro fator apresentado neste modelo. O atributo da motivação individual para assumir papéis a outro nível de responsabilidade e impacto na organização (desenvolver equipas ou fazer acontecer) é mais outra forma de distinguir os *High Potentials* de outros colaboradores.

Os restantes dois fatores, *Skills* e *Conhecimento*, são apresentados como aqueles que facilmente podem ser adquiridos pelos colaboradores e, por isso, com menor capacidade discriminatória na identificação de *High Potentials*.

Também Ready, Conger, & Linda (2010) apresentam a sua proposta de fatores que distinguem os *High Potentials*. Os *High Potentials*, afirmam estes autores, para além de entregarem sempre resultados credíveis, dominarem novos tipos de especialização e reconhecerem que o comportamento conta, possuem uma anatomia própria em que se distinguem dos restantes colaboradores por possuírem quatro *Fatores X* intangíveis:

- Fator X: Motivação pela excedência
- Fator X: Capacidade de aprendizagem catalítica
- **Fator X**: Espírito empreendedor
- Fator X: Sensores dinâmicos para evitar riscos desnecessários

Por seu lado, Fernândez-Aráoz (2014) sugere 5 características que caracterizam os *High Potentials* resultantes do conhecimento adquirido ao longo de mais de 20 anos de pesquisa nesta área:

- Motivação para crescerem profissionalmente e abarcarem novos desafios, não por questões de egoísmo pessoal mas, de uma forma humilde, contribuindo assim para a organização;
- Curiosidade por novas abordagens, novos métodos de trabalho, etc.;
- Insight, adquirirem conhecimento profundo e preciso da organização e de como ela funciona de forma quase que intuitiva;
- Engagement, compromisso claramente assumido para com a organização
- **Determinação** em alcançarem os seus objetivos e lutarem por aquilo em que acreditam.

Nesta exposição que aspira à identificação exaustiva de fatores e atributos que caracterizam os *High Potentials*, finaliza-se com a visão da organização através da perspetiva de Jack Welch, não pretendendo desconsiderar outros modelos ou opiniões de outros *expertises* na matéria em exploração.

Curiosamente, Welch (2007) apresenta a expressão *4E+1P* para identificar os colaboradores que formam as equipas vencedoras e cujos atributos foram identificados ao longo da sua carreira no Grupo General Electric (GE). Devido às suas características pessoais, participou sempre ativamente nos momentos de avaliação de desempenho acompanhando os Diretores de Recursos Humanos das várias empresas do Grupo GE. Nesses momentos, foi-se apercebendo que as equipas que se destacavam pelo seu sucesso integravam pessoas que possuíam os seguintes atributos:

- E Energia Positiva (apreciam a mudança)
- **E Estimular os outros** (postura otimista que contagia os outros colaboradores)
- **E** *Edge* (tomam decisões difíceis, assumindo o risco associado)
- **E Execução** (bom desempenho com resultados propostos alcançados)
- P Paixão

A tabela 2.6 apresenta uma visão agregada dos fatores e atributos apresentados ao longo deste capítulo.

Fatores de Performance e Atributos associados na caracterização de Talentos								
Background								
Atributo	Descrição	Autores						
Idade	-	Jantan, Hamdan, & Othman (2010)						
		D'Amato & Herzfeldt (2008)						
		Troni (2015)						
		Deloitte (2015)						
Género	-	Jantan, Hamdan, & Othman (2010)						
Nacionalidade	-	Jantan, Hamdan, & Othman (2010)						
Escolaridade	-	Jantan, Hamdan, & Othman (2010)						
		D'Amato & Herzfeldt (2008)						
Formação técnica e comportamental	Formações complementares	Jantan, Hamdan, & Othman (2010)						
		D'Amato & Herzfeldt (2008)						
Ano	Ano de admissão e de promoção	Jantan, Hamdan, & Othman (2010)						
		D'Amato & Herzfeldt (2008)						
Função	Grupo funcional e/ou nível hierárquico	Jantan, Hamdan, & Othmar (2010)						

(continua)

-	nance e Atributos associados na caracteriza	-yao ao Talemos (communicación)
Avaliação de Desempe	nho T	1
Atributo	Descrição	Autores
Avaliação de desempenho	Desempenho consistente na execução das responsabilidades	Jantan, Hamdan, & Othman (2010) Welch (2007)
Fator Conhecimento e	Skills	
Atributo	Descrição	Autores
Conhecimentos gerais, da área de atuação e técnicos	-	Jantan, Hamdan, & Othman (2009, 2010) Fernández-Aráoz, Groysberg, & Nohria (2011)
Competências de gestão	-	Jantan, Hamdan, & Othman (2010) Fernández-Aráoz, Groysberg, & Nohria (2011)
Expertise	Competências reconhecidas sobre determinado tema	Jantan, Hamdan, & Othman (2009, 2010) Fernández-Aráoz, Groysberg, & Nohria (2011)
Comunicação verbal e escrita	-	Jantan, Hamdan, & Othman (2010) Fernández-Aráoz, Groysberg, & Nohria (2011)
Fator Caraterísticas Pe	ssoais	
Atributo	Descrição	Autores
Liderança	Envolve outras pessoas, procura conhecimento e transforma informação em novas ideias	Jantan, Hamdan, & Othman (2009, 2010) Fernández-Aráoz, Groysberg, & Nohria (2011)
Sentido de organização e disciplina	Estrutura e aborda com método a informação	Jantan, Hamdan, & Othman (2009, 2010)
Relacional	Estabelece relações e contagia positivamente através da sua postura otimista	Jantan, Hamdan, & Othman (2009, 2010) Welch (2007)
Cooperação	Disponibiliza-se para colaborar com outros	Jantan, Hamdan, & Othman (2009, 2010)
Pro-atividade	Toma iniciativa	Jantan, Hamdan, & Othman (2009)
Curiosidade	Gosta de implementar novas abordagens e novos métodos de	Fernândez-Aráoz (2014)

(continua)

trabalho

Fatores de *Performance* e Atributos associados na caracterização de Talentos (continuação)

Fator Caraterísticas Pessoais (continuação)

Atributo	Descrição	Autores			
Determinação	Insiste no alcançar dos seus objetivos e no que acreditam	Fernândez-Aráoz (2014)			
Inovador	Desenvolve soluções alternativas às existentes	Jantan, Hamdan, & Othman (2009, 2010)			
Empreendedor	Arrisca na apresentação de novas soluções	Ready, Conger, & Linda (2010			
Aprendizagem catalítica	Adquire novos conhecimentos, querendo saber sempre mais	Ready, Conger, & Linda (2010			
Motivação pela excelência	Procura continuamente alcançar resultados sempre melhores, para crescer profissionalmente e abarcar novos desafios	Ready, Conger, & Linda (2010) Fernândez-Aráoz (2014)			
Evita riscos	Atento a riscos desnecessários	Ready, Conger, & Linda (2010			
Edge / Decisor	Toma e responsabiliza-se por decisões difíceis	Jantan, Hamdan, & Othman (2009) Jantan, Hamdan, & Othman (2010) Welch (2007)			
Estável	Forma consistente de ser e de estar	Fernández-Aráoz, Groysberg, & Nohria (2011)			
Insigh	Conhece profundamente a organização, quase de forma intuitiva	Fernândez-Aráoz (2014)			
Engagement	Comprometimento com os objetivos da organização o que promove a fidelização em detrimento da vontade de mudança para outras organizações	Fernández-Aráoz, Groysberg, & Nohria (2011) Fernândez-Aráoz (2014)			
Energiger	Comportamento contagiante de atitude/energia positiva junto dos indivíduos da organização	Fernández-Aráoz, Groysberg, & Nohria (2011) Welch (2007)			
Paixão	Tem gosto pelo que faz empenhando-se continuamente, sem esforço	Welch (2007)			
Judgement/Capacida de de análise	Apresenta questões estruturadas e resolve problemas com rigor analítico (2010) YSC (2015)				
Drive/Motivação	Possui motivação baseada na sua autoconfiança, apresenta iniciativas e conduz ações com impacto na organização	YSC (2015)			

(continua)

Fatores de Performance e Atributos associados na caracterização de Talentos (continuação) Fator Resultado do Trabalho Realizado Atributo Descrição/Exemplos **Autores** Influence/Influência Capaz de percecionar a influência que Jantan, Hamdan, & Othman exerce sobre os indivíduos na (2009, 2010)organização com o propósito de YSC (2015) contribuir positivamente para a Fernández-Aráoz, Groysberg, organização & Nohria (2011) Quantidade e Trabalho realizado com rigor Jantan, Hamdan, & Othman Qualidade do trabalho (2010)realizado Welch (2007) Trabalho realidade de acordo com o Cumprimento de Jantan, Hamdan, & Othman requisitos estipulado (2010)Welch (2007) Eficácia Trabalho realizado dentro do prazo Jantan, Hamdan, & Othman estipulado (2010)Fator Atividades e Contribuição Atributo Descrição/Exemplos **Autores**

Tabela 2.6 - Lista de exemplos de atributos por Fatores de *Performance* dos Talentos (vários autores)

Jantan, Hamdan, & Othman

(2010)

Iniciativas com a organização e/ou

comunidade onde se insere

Atividades com a

sociedade

3. METODOLOGIA

3.1. ENQUADRAMENTO DO PROBLEMA A ESTUDAR NA ORGANIZAÇÃO

Este Trabalho de Projeto procurou prever as classificações dos Talentos na Organização. Para tal, ao longo da metodologia aplicou conceitos e processos existentes na Organização que importa primeiramente apresentar e enquadrar para garantir uma adequada leitura e compreensão da metodologia aplicada. Assim, os primeiros subcapítulos visam apresentar os processos *Talent Review* e Gestão do Desempenho por Objetivos (GDO).

Posteriormente, será apresentada a metodologia seguida neste Trabalho de Projeto.

3.2. ENQUADRAMENTO DO PROCESSO DA ORGANIZAÇÃO TALENT REVIEW 2015

3.2.1. Caracterização do Processo Talent Review

O processo *Talent Review* providencia uma abordagem estruturada para identificar, rastrear e desenvolver os Talentos da Organização.

A abordagem foca-se nas competências individuais (*Potential*), na avaliação de desempenho e nas suas capacidades com vista a identificar o *pipeline* de Talentos da Organização, em particular:

- Acompanhar e satisfazer as necessidades de curto e longo prazo a nível de liderança (pipeline de Talentos);
- Identificar os Talentos e os seus possíveis próximos passos;
- Desenhar planos de sucessão;
- Avaliar o desempenho individual e definir planos de desenvolvimento do colaborador;
- Criar programas específicos para desenvolvimento de alto nível e de carreira que melhoram a atração e desenvolvimento de Talentos na Organização.


As competências individuais (*Potential*) do colaborador interno são avaliadas pela sua chefia atendendo às competências *core* da função que desempenha na escala *Low (1), Solid (2)* e *High (3)* em 3 dimensões:

- Judgement
- Drive
- Influence

O significado destas 3 dimensões encontra-se apresentado no capítulo 2, Revisão da Literatura. A média obtida nas 3 dimensões determina a avaliação das competências individuais (*Potential*) e apresenta-se no eixo vertical da Matriz de classificação de Talentos da Organização.

A avaliação de desempenho resulta da aplicação da escala 0 (*Negative*) a 5 (*Outstanding*) relativamente ao resultado alcançado da contribuição financeira/business results do ano em avaliação.

A classificação final do nível de Talento do colaborador interno é obtida de acordo com a matriz apresentada na figura 3.2:



Legenda:WP – Well Placed PI - Internal Placement

Issue

Avaliação de Desempenho

Figura 3.1 – Matriz de classificação de Talentos da Organização

Sempre que necessário, os resultados são calibrados pela Direção de Recursos Humanos de forma a garantir que os mesmos seguem uma distribuição normal.




Figura 3.2 – Distribuição normal das classificações obtidas via Matriz de Talentos

Da análise da figura 3.3 constata-se que:

≈15% dos colaboradores internos serão identificados com tendo problemas para resolver ou sendo demasiado novos para integrarem este processo;

≈70%: dos colaboradores internos serão identificados como estando bem colocados a nível funcional dentro da Organização;

≈15% dos colaboradores internos serão identificados como os Talentos da Organização em 3 níveis high potential, potential & high performers.

3.2.2. Caracterização dos dados e resultados do Talent Review 2015

A aplicação do processo do *Talent Review* a todos os níveis da Organização foi implementada apenas em 2015, pelo que, não existem dados históricos para a totalidade dos colaboradores internos.

Constituem os colaboradores internos, pessoas das Equipas de Negócio (com objetivos de vendas e de rentabilidade) e das Equipas de Suporte (departamentos transversais, sem objetivos de negócio).

Os colaboradores internos distribuem-se maioritariamente pelo sexo feminino; a antiguidade na Organização é bastante dispersa em termos de representatividade e mais de 50% dos colaboradores internos possuem licenciatura (figura 3.4).




Figura 3.3 – Caracterização do background dos colaboradores internos da Organização

Atualmente, encontra-se em curso reformulação de funções das várias Equipas com a criação de processos de negócio e de suporte inexistentes até a um passado recente. Este novo enquadramento

não está ainda totalmente documentado ao nível do descritivo de funções, pelo que, admite-se que as avaliações efetuadas pelas chefias possam ser afetados por algum grau de subjetividade nas variáveis competências *core* (*Judgement*, *Drive* e *Influence*), variáveis do processo que contribuem o apuramento automático da avaliação das competências individuais (*Potential*).

No caso dos colaboradores das Equipas de Suporte (sem objetivos de negócio), o preenchimento da variável contribuição financeira/business results não resulta da aplicação de critérios claros pela chefia respetiva podendo passar pela utilização dos resultados da contribuição financeira/business results da Organização, do resultado do desempenho obtido no processo GDO ou de outro critério não estipulado.

Por outro lado, existem casos particulares de colaboradores das Equipas de Negócio que transitaram de chefia no decorrer do ano, mudaram de área ou que trabalham com várias Equipas de Negócio, e cujos resultados da variável contribuição financeira/business results não representam o seu desempenho efetivo na vertente da rentabilidade do negócio, sendo o resultado definido caso a caso.

Estes casos condicionam igualmente o apuramento do resultado da classificação do Talento, verificando-se avaliações não totalmente representativas do colaborador interno. Nestas situações, é necessária a intervenção manual na base de dados pela Direção dos Recursos Humanos.

Em 2015, a distribuição obtida das classificações de Talentos dos colaboradores internos da Organização caracterizou-se por (figura 3.5):



Figura 3.4 – Distribuição das classificações dos Talentos da Organização

3.3. ENQUADRAMENTO DO PROCESSO DA ORGANIZAÇÃO GDO

3.3.1. Caracterização do processo GDO

O processo Gestão do Desempenho por Objetivos, GDO, traduz-se sumariamente num conjunto de atividades de identificação de objetivos (indicadores e metas a alcançar) definidos no início de cada ano entre o colaborador interno e a sua chefia, com um momento de *follow-up* a meio do ano e avaliação dos resultados alcançados terminado o ano através das métricas apropriadas de monitorização de cada indicador.

O processo envolve 3 tipos de objetivos:

- Objetivos Financeiros: incluem os indicadores contribuição financeira/business results e a avaliação do cliente (externo para as Equipas de Negócio ou interno para as Equipas de Suporte);
- Objetivos Individuais: conjunto de indicadores identificados para cada colaborador interno adequados à função que desenvolve;
- Desenvolvimento de Competências: objetivos adequados à melhoria contínua do desempenho de cada colaborador interno.

Os objetivos são avaliados numa escala de 0% a 130%, considerando-se resultados excelentes quando a avaliação total dos objetivos excede os 115%, ou resultados abaixo das expectativas nos casos abaixo de 85%.

3.3.2. Caracterização dos dados e resultados do GDO 2013-2015

Os resultados calibrados do último triénio apresentam-se na figura 3.6:




Figura 3.5 – Distribuição normal dos resultados do processo GDO na Organização

O resultado da avaliação de desempenho dos colaboradores internos caracteriza-se por apresentar uma distribuição normal centrada à volta do valor de cerca de 100%. O número de colaboradores com avaliações excelentes ou não satisfatórias representarão cerca de 15% respetivamente.

3.4. METODOLOGIA PROPOSTA

O Trabalho de Projeto implementado abordou dados dos colaboradores internos da Organização disponibilizados pela Direção de Recursos Humanos visando a identificação antecipada dos seus Talentos para 2016.

Os dados decorrem da existência do processo anual denominado *Talent Review* (45 variáveis) e que visa atribuir uma classificação a cada colaborador interno de acordo com a Matriz de Talentos. Este processo é *input* para gestão dos recursos humanos e para a política de Retenção de Talentos na Organização.

A implementação do Trabalho de Projeto no contexto da Organização passou por uma primeira análise do processo do *Talent Review* ao nível do conhecimento dos conceitos utilizados, significado das variáveis que constituem o modelo, critérios de preenchimento da base de dados gerida pela Direção de Recursos Humanos, análise dos dados e dos resultados obtidos no início de 2015.

A exploração da revisão da literatura levou à identificação de 3 tipos de fatores relacionados com a performance dos indivíduos:

- 1. Competências individuais (termo utilizado na Organização: Potential)
- 2. Avaliação de desempenho
- 3. Background

Na Organização, estas 3 componentes integram o processo do *Talent Review*. No entanto, não existem dados históricos que permitam a obtenção de um modelo preditivo que disponibilize à Organização a previsão das classificações futuras identificadas na Matriz de Talentos relativamente aos seus colaboradores internos.

Ao observar atentamente a base de dados do processo do *Talent Review*, constatou-se que a componente *Background* não tem impacto direto nas classificações dos Talentos. Por outro lado, o processo de avaliação de desempenho Gestão de Desempenho por Objetivos, GDO, (7 variáveis) é *input* para a criação de dados do processo alvo de análise. Este processo, GDO, existe na Organização desde 2012, pelo que, a estratégia de implementação do Trabalho de Projeto passou por, numa primeira fase, analisar o processo *Talent Review* 2015, numa segunda fase, abordar o processo GDO de forma a criar o modelo preditivo e, numa última fase, identificar os Talentos de 2016 (figura 3.6):




Figura 3.6 Fases da metodologia aplicada à previsão das classificações dos Talentos 2016

As principais atividades seguidas na metodologia do Trabalho de Projeto descrevem-se de seguida:

FASE 1 | Talent Review 2015

- Obtenção da base de dados Talent Review 2015 integrando elementos de background dos colaboradores internos oriundos da aplicação informática de Gestão de Recursos Humanos da Organização;
- 2. Preparação e análise da base de dados *Talent Review* 2015:
 - a. Eliminação de observações (colaboradores internos) com vários valores omissos;
 - b. Identificação das variáveis relevantes para a obtenção das classificações de Talentos;

FASE 2 | GDO 2012-2016

- 3. Preparação e análise da base de dados Gestão do Desempenho por Objetivos (GDO) (2012-2015):
 - a. Eliminação das observações (colaboradores internos) com vários anos sem dados;

- b. Criação de novos dados a partir de médias ou assumindo os valores do ano anterior, nas situações de existência de poucos valores omissos do colaborador interno;
- 4. Criação do *dataset* GDO (2012-2014), com variável *target* GDO 2015 para obtenção do modelo preditivo utilizando a aplicação SAS Miner 9.3;
- 5. Apresentação do *dataset* GDO (2013-2015) ao modelo para obtenção dos valores do GDO 2016;
- 6. Análise da accuracy do modelo preditivo.

FASE 3 | Talent Review 2016

7. Obtenção para 2016 das novas classificações dos colaboradores internos de acordo com a Matriz de Talentos da Organização, utilizando para tal, os valores previstos do GDO 2016 e mantendo as avaliações das competências individuais de 2015 dos colaboradores internos (devido à ausência de dados históricos).

3.5. CONSTITUIÇÃO DOS DATASETS DO TRABALHO DE PROJETO

Conforme apresentado nos pontos anteriores, a avaliação e obtenção de resultados do processo *Talent Review*, têm algumas condicionantes ao nível dos critérios utilizados na criação dos dados e possíveis interferências de subjetividade da chefia respetiva. Os dados disponíveis são apenas de 2015.

Assim, visando prever as classificações dos Talentos em 2016, foi definida a estratégia de construir um modelo preditivo com base nos resultados históricos do processo GDO, cujos dados estão disponíveis de 2012-2015, e cujos critérios utilizados para avaliação dos colaboradores internos são mais consistentes repercutindo-se na qualidade dos dados passíveis de serem utilizados para criação de modelos preditivos.

3.5.1. Dataset Talent Review 2015

Preparação dos dados

Os dados utilizados no *dataset* para obtenção da identificação dos novos Talentos em 2016 resultam das seguintes variáveis de *input*:

- Variáveis de caracterização das competências individuais (Potential);
- Variáveis de avaliação de desempenho.

As variáveis de *Background* não têm impacto direto na obtenção das classificações de Talento na Organização, pelo que, não serão consideradas neste estudo.

A preparação dos dados passou pelas seguintes fases:

- Integração dos dados de background dos colaboradores internos que resultam da aplicação informática de Gestão de Recursos Humanos da Organização na base de dados do Talent Review de 2015;
- Análise da base de dados do *Talent Review* 2015 para identificação dos colaboradores internos com qualidade dos dados nas várias componentes cumulativamente:
 - a. Caracterização do background;
 - b. Competências individuais;
 - c. Avaliação de desempenho;
 - d. Classificação do Talento;
- Constituição do dataset Talent Review eliminando as observações com dados omissos no período em análise.

Do ficheiro disponibilizado com 273 observações, foram consideradas apenas 236 observações para integrarem o *dataset Talent Review* 2015.

3.5.2. Dataset GDO 2012-2015

Preparação dos dados

Os dados a utilizar no *dataset* para obtenção do modelo preditivo dos valores de GDO resultam das seguintes variáveis de *input* para cada ano:

- GDO Objetivos Financeiros (resultado total);
- GDO Objetivo Contribuição Financeira (componente parcial dos Objetivos Financeiros);
- GDO Satisfação do Cliente (componente parcial dos Objetivos Financeiros);
- GDO Objetivos Individuais (indicadores específicos para cada colaborador interno);
- GDO Objetivos de Desenvolvimento de Competências (indicadores específicos para cada colaborador interno).

A variável target definida foi o GDO global do ano seguinte.

A preparação dos dados passou pelas seguintes fases:

- Criação da base de dados GDO com resultados históricos de 2012-2015;
- Eliminação de observações com dados omissos no período em análise;
- Criação de novos valores para alguns valores omissos por colaborador interno através da obtenção dos valores médios de anos anteriores ou alocação de valor obtido no ano imediatamente anterior, garantindo as regras (%) de constituição do modelo GDO;
- Constituição do dataset com dados do processo GDO de 2012-2014 e variável target com os valores de GDO em 2015 para obtenção do modelo preditivo;
- Constituição do dataset com dados do processo GDO de 2013-2015 para apresentação ao modelo preditivo e obtenção dos valores para a variável target do GDO em 2016;
- Caracterização das variáveis na aplicação SAS Miner 9.3;
- Análise da presença de outliers utilizando a aplicação SAS Miner 9.3.

Do ficheiro disponibilizado com 269 observações, foram consideradas apenas 125 observações para integrarem o *dataset* GDO.

Pré-processamento dos dados

Da análise das variáveis do *dataset* GDO e conhecimento do respetivo processo, decidiu-se criar novas variáveis através de indicadores que caracterizem o processo com vista à obtenção de um modelo com maior capacidade preditiva. Assim, foram introduzidas 4 novas variáveis obtidas através das seguintes fórmulas, para cada um dos anos N, N-1 e N-2:

Colaborador (ano) = Objetivos Individuais(ano)+Objetivos Desenvolvimento de Competências(ano)

GDO (ano)

GDO Médio =
$$\Sigma$$
 GDO (anos N, N-1, N-2)
GDO (ano)

Face ao elevado número de variáveis disponíveis, procedeu-se de seguida à identificação das que poderiam integrar o modelo visando, desta forma, contribuir para uma representação espacial menos esparsa e diminuir a probabilidade da modelação ser condicionada negativamente pelo fenómeno da Maldição da Dimensionalidade.

A seleção das variáveis atendeu aos critérios *worth*, correlações e *clustering* (por esta ordem) apresentados nas figuras seguintes.




Figura 3.7 – Análise das variáveis a integrar o modelo preditivo GDO através do critério Worth

O critério *Worth* indica as variáveis com maior relevância na modelação preditiva identificando-as através sua ordenação da esquerda para a direita (figura 3.7). Observando o gráfico, parte das variáveis mais interessantes são variáveis transformadas através dos indicadores que caracterizam o processo GDO.

ile Edit View Window											
🖺 🖺 🞒 🏢 🇳											
SPEARMAN											
NAME	Cliente_Medi a	Cliente_N	Cliente_N_1	Cliente_N_2	Colab_Media	Colab_N	Colab_N_1	Colab_N_2	GDO_ANO_ N	GDO_ANO_ N_1	GDO_AN N_2
Cliente_Media	1	0.540719	0.763569	0.727776	0.194167	-0.11843	0.345025	0.198661	-0.34102	-0.59942	-0.5
Cliente_N	0.540719	1	0.245647	0.137762	-0.10315	-0.15615	0.002502	-0.07882	-0.77966	-0.19227	-0.0
Cliente_N_1	0.763569	0.245647	1	0.404309	0.248822	-0.14253	0.52195	0.180611	-0.09357	-0.88689	-0.2
Cliente_N_2	0.727776	0.137762	0.404309	1	0.24321	0.043311	0.184638	0.264555	-0.02308	-0.2365	-0.8
Colab_Media	0.194167	-0.10315	0.248822	0.24321	1	0.551722	0.663742	0.597104	0.129732	-0.15103	-0.2
Colab_N	-0.11843	-0.15615	-0.14253	0.043311	0.551722	1	0.098465	-0.03627	0.043723	0.239093	-0.
Colab_N_1	0.345025	0.002502	0.52195	0.184638	0.663742	0.098465	1	0.286993	0.12204	-0.42998	-0.1
Colab_N_2	0.198661	-0.07882	0.180611	0.264555	0.597104	-0.03627	0.286993	1	0.116603	-0.17157	-0.2
GDO_ANO_N	-0.34102	-0.77966	-0.09357	-0.02308	0.129732	0.043723	0.12204	0.116603	1	0.137872	0.0
GDO_ANO_N_1	-0.59942	-0.19227	-0.88689	-0.2365	-0.15103	0.239093	-0.42998	-0.17157	0.137872	1	0.20
GDO_ANO_N_2	-0.55915	-0.08163	-0.29898	-0.84464	-0.22313	-0.0747	-0.13975	-0.27525	0.04838	0.208092	
GDO_Medio	-0.79032	-0.54148	-0.6191	-0.5321	-0.11495	0.076172	-0.19641	-0.15227	0.603109	0.640894	0.60
GDO_TARGET	-0.22742	-0.24582	-0.14854	-0.09565	0.061244	-0.03423	0.040488	0.05327	0.311266	0.216746	0.11
Lucro_Medio	-0.37419	-0.14097	-0.3767	-0.28671	-0.76355	-0.40259	-0.69856	-0.43142	0.079439	0.282518	0.27
Lucro_N	0.037234	0.021957	0.112897	-0.04117	-0.45674	-0.86418		0.036482	0.054005	-0.21794	0.07
Lucro_N_1	-0.37476	-0.15988	-0.51932	-0.16655	-0.53024	-0.13956		-0.16362	0.043122	0.441979	0.16
Lucro_N_2	-0.41728	-0.18392	-0.37029	-0.37814	-0.56529	-0.03949	-0.45033	-0.70194	0.070584	0.322066	0.32
OBJ_COMPT_ANO_N	-0.02114	-0.13205	0.013435	0.041912	0.276629	0.535054	0.062451	0.009199	0.13194	-0.00368	-0.0
OBJ_COMPT_ANO_N_1	-0.01405	-0.17859	0.02119	0.077499	0.445263	0.332171	0.316355	0.086595	0.26683	0.056711	-0.0
OBJ_COMPT_ANO_N_2	0.007558	0.051874	0.081966	-0.16044	0.263207	0.035	0.126435	0.393054	-0.09936	-0.15797	0.20
OBJ_CONTRIB_ANO_N	-0.14222	-0.35826	0.046655	-0.06551	-0.24553	-0.61641	0.008994	0.059625	0.538044	-0.09708	0.13
OBJ_CONTRIB_ANO_N_1	-0.4927	-0.22408	-0.69748	-0.18381	-0.44522	-0.02963	-0.80394	-0.14111	0.099737	0.666903	0.17
OBJ_CONTRIB_ANO_N_2	-0.55698	-0.16496	-0.42071	-0.65542	-0.51839	-0.0618	-0.39521	-0.64239	0.038183	0.329307	0.67
OBJ_FIN_ANO_N	-0.22475	-0.3855	-0.05141	-0.07984	-0.29459	-0.5862	-0.07651	0.006504	0.61926	0.012269	0.15
OBJ_FIN_ANO_N_1	-0.47479	-0.19614	-0.70288	-0.14481	-0.47122	-0.009	-0.80928	-0.16388	0.096535	0.711972	0.12
OBJ_FIN_ANO_N_2	-0.40555	-0.07411	-0.26322	-0.56112	-0.53144	-0.05807	-0.29991	-0.72239	0.032746	0.239304	0.64
OBJ_INDIV_ANO_N	-0.28053	-0.58231	-0.12462	0.040736	0.523658	0.67649		0.079546	0.60958	0.249745	-0.0
OBJ_INDIV_ANO_N_1	-0.26543	-0.08306	-0.35151	-0.13289	0.260637	0.192722	0.341447	0.025869	0.129162	0.527734	0.13
OBJ_INDIV_ANO_N_2	-0.35065	-0.15342	-0.15886	-0.49638	0.229468	-0.0328	0.070774	0.433343	0.194939	0.147454	0.5
OBJ_SAT_CLI_ANO_N	0.417363	0.367255	0.360409	0.283557	0.039282	-0.18573	0.20523	0.03868	0.211299	-0.19807	-0.0
OBJ_SAT_CLI_ANO_N_1	0.519756	0.253522	0.500289	0.3178	0.098589	0.017807	0.262532	-0.05522	0.063398	-0.16301	-0.0
OBJ_SAT_CLI_ANO_N_2	0.536658	0.214675	0.296886	0.598343	0.087613	-0.01913	0.131233	0.012261	0.014587	-0.10186	-0.1
dataobs	-0.41523	-0.37162	-0.27045	-0.37524	-0.11033	-0.09177	-0.04746	-0.04817	0.249441	0.163621	0.28

Figura 3.8 – Análise das variáveis a integrar o modelo preditivo GDO através do critério correlação *Spearman*

Observando a figura 3.8, constata-se que a maioria das variáveis não tem correlação significativa (<80%). Para as variáveis com maior relevância na modelação preditiva identificadas através do critério *Worth*, temos apenas as seguintes variáveis redundantes a ter em consideração:

Cliente_Média & Cliente_Ano_N_1: correlação 76%

Obj_Fin_Ano_N & OBJ_CONTRIB_ANO_N: correlação 95%

Obj_Fin_Ano_N & Lucro_N: correlação 73%

OBJ_CONTRIB_ANO_N & Lucro_N: correlação 80%

Lucro_N_1 & Lucro_Medio: correlação 80%




Figura 3.9 – Análise das variáveis a integrar o modelo preditivo GDO através do critério Clustering

As variáveis pertencentes aos mesmos clusters têm pouca relevância na modelação preditiva.

Identificando as variáveis com maior relevância da figura 3.7, as variáveis redundantes pela sua correlação na figura 3.8 e as variáveis com pouca relevância quando pertencentes aos mesmos *clusters* via figura 3.9, resultam as variáveis selecionadas do *dataset* a considerar no modelo (nó Matadata):

•	ID_COLAB	(Número do Colaborador)
•	GDO_Target	(Valor do GDO do ano seguinte)
•	GDO_Medio	(Valor médio do GDO de 3 anos)
	OBJ_FIN_ANO_N	(Resultado do Objetivo Financeiro do ano N)
•	Cliente_N	(Resultado da Avaliação da Satisfação do Cliente no ano N)
•	Colab_N	(Resultado do indicador Colaborador no ano N)
•	Lucro_N_1	(Resultado do indicador Lucro no ano N-1)
•	Cliente_N_1	(Resultado do indicador Cliente no ano N-1)
•	Colab_N_1	(Resultado do indicador Colaborador no ano N-1)
•	Lucro_N_2	(Resultado do indicador Lucro no ano N-2)

3.6. Processo Preditivo GDO 2016

O dataset constituído para obter o modelo preditivo é bastante redutor em termos de números de observações (total de 125). Esta situação, aliada à necessidade de substituição dos valores omissos por valores expectáveis para o processo GDO, promoveu a estratégia da criação de um diagrama na aplicação SAS Miner 9.3 com bastantes variantes na parametrização dos nós para os algoritmos utilizados (Árvores de Decisão e Redes Neuronais) para identificar de forma mais eficaz o modelo com melhor capacidade preditiva (Anexo 1).

Os nós das Árvores de Decisão foram parametrizados variando os critérios de *Splitting Rule* para as variáveis intervalares (*Variance* e *ProbF*), tendo-se mantido a parametrização das variáveis nominais

e ordinais (*Entropy*), assim como, o parâmetro de profundidade da árvore até 6 níveis. A medida de avaliação usada para crescimento da árvore foi o erro quadrado médio.

Os nós das Redes Neuronais foram parametrizados variando o número de camadas escondidas na rede entre 1 e 3. O critério de seleção do modelo usado foi o erro médio.

Atendendo ao facto da variável *target* ser numérica intervalar, a seleção do melhor modelo foi parametrizado para atender ao menor erro quadrado médio.

A obtenção dos resultados da variável *target* para 2016, resultou do processo *Score* aplicando o modelo selecionado ao *dataset* GDO do período 2013-2015.

3.7. MATRIZ DE TALENTOS 2016

A obtenção das novas classificações dos Talentos da Organização em 2016 baseou-se na:

- Utilização dos valores do modelo preditivo GDO para obtenção da avaliação de desempenho dos colaboradores internos;
- Aplicação das mesmas avaliações obtidas nas características individuais em 2015, por não existirem dados históricos disponíveis para essas variáveis e assumindo que as características individuais não mudam significativamente de um ano para o outro.

A avaliação de desempenho do processo *Talent Review* em vigor aplica a escala de 0 (*negative*) a 5 (*Outstanding*) e decorre dos resultados alcançados na contribuição financeira/*business results* enquanto o processo GDO tem uma escala que vai de 0 a 130%.

Assim, houve a necessidade de criar um processo de correspondência entre as escalas dos dois processos de acordo com a tabela 3.1:


Avaliação de desempenho	Talent Review	GDO		
High (3)	[3,5;[[110%; 130%]		
Solid (2)	[2,8; 3,5[[60%; 110%[
Low (1)	[0; 2,8[[0%; 60%[

Tabela 3.1 – Tabela de correspondências da avaliação de desempenho TR vs GDO

Dado que os critérios de classificação do processo *Talent Review* da Organização não atenderem a intervalos equidistantes, pelo facto do processo GDO instituído na Organização atribuir classificações nos extremos opostos com intervalos de dimensões diferentes ([100% - 130%] e [0% - 60%[) e ainda, uma vez que o modelo preditivo tem um erro associado, foi definida a estratégia de bonificar a

classificação *High* para o desempenho obtido via processo GDO a iniciar-se em 110% ao invés de 115%.

A nova Matriz de classificação de Talentos em 2016, terá a seguinte configuração (figura 3.10):



Legenda: WP – Well Placed PI - Internal Placement Issue

Figura 3.10 – Matriz de classificação de Talentos 2016

Para obtenção do *dataset* do *Talent Review* 2016, foram implementadas as seguintes atividades por cada colaborador interno:

- Transformação dos resultados do GDO 2016 para a escala High (3), Solid (2) e Law (1) de acordo com os critérios da nova Matriz de classificação de Talentos;
- Multiplicação da média das classificações das características individuais (*Potential*) pelas classificações do GDO 2016 obtidos no ponto anterior;
- Obtenção da nova classificação dos Talentos.

A obtenção da nova classificação dos Talentos resultou da aplicação da seguinte regra:

```
=SE(GDO=1;"PI";

SE(GDO*POTENTIAL=9;"HIGH_POT";

SE(GDO*POTENTIAL=6;"POTENTIAL";

SE(GDO*POTENTIAL=3;"HIGH_PERF";

"WELL_PLACED"))))
```

No capítulo seguinte, apresentam-se os resultados alcançados.

4. RESULTADOS E DISCUSSÃO

4.1. APRESENTAÇÃO DOS RESULTADOS OBTIDOS

4.1.1. Resultados obtidos para o processo GDO 2016

Face ao diagrama criado no SAS Miner 9.3, o modelo seleccionado foi o resultante da parametrização da Rede Neuronal com 2 camadas escondidas, cujo menor erro quadrado médio ditou a sua selecção entre os outros modelos (tabela 4.1):

Selected	Model Description	Selection Criterion:	Valid:	Valid:
Model		Valid: Average Squared Error	Sum of Squared Error	Maximum Absolute Error
Υ	Neural Network 5 (H2)	0.007575941621994574	0.18939854054986435	0.22987271015137722
	Neural Network 1 (H1)	0.009884472980399113	0.24711182450997782	0.31640622663313480
	Neural Network 4 (H3)	0.011191095639940958	0.27977739099852394	0.27214521605872144
	Decision Tree 1 Variance	0.011759349779560000	0.29398374448900000	0.28386259999999996
	Decision Tree 2 ProbF	0.011759349779560000	0.29398374448900000	0.28386259999999996
	Decision Tree 3 Variance	0.011759349779560000	0.29398374448900000	0.28386259999999996
	Decision Tree 4 (ProbF)	0.011759349779560000	0.29398374448900000	0.28386259999999996
	Neural Network 2 (H2)	0.012300107530008972	0.30750268825022430	0.26562369471287917
	Neural Network 3 (H3)	0.017563757716104356	0.43909394290260890	0.46233322667139526

Tabela 4.1 – Comparação dos erros dos vários modelos preditivos

Os resultados estimados para a variável GDO em 2016, quando comparados com os resultados de 2015, apresentam diferenças que chegam a ter uma amplitude significativa (tabelas 4.2, 4.3 e 4.4).

Para melhor compreender os resultados alcançados e atendendo ao baixo número de observações, foi igualmente apresentado ao modelo o *dataset* com os dados de *input* à modelação para averiguar a real capacidade preditiva do modelo, igualmente apresentados nas tabelas que se seguem.

ID	OBJ FIN	OBJ INDV	ОВЈ СОМРТ	GDO	GDO Médio	GDO 2015	Δ	Δ	GDO 2016
COLAB		_		_				Prev15-Média2015	previsto 🔻
A0654	25%	16%	8%	49%	75%				83%
A0109	55%	20%	4%	79%	92%		_	7	92%
A0393	30%	29%	8%	66%	86%	88%	-	-	88%
A0084	25%	28%	10%	63%	79%	83%		4%	83%
A0705	44%	31%	10%	85%	102%	103%	7		83%
A0059	24%	48%	8%	80%	88%	97%	-		88%
A0255	12%	51%	10%	73%	83%	85%	-	-	76%
A0233	41%	38%	10%	89%	97%	100%	-		84%
A0678	25%	40%	8%	73%	91%	83%	_	'	83%
A0593	12%	54%	12%	78%	89%	88%	-	<u>×</u>	87%
			1%		95%		-	Y	
F0006	55%	37%		92%		102%	-	7	84%
A0384	41%	38%	10%	89%	91%	98%	-	-	84%
A0328	49%	28%	13%	91%	96%	99%	-	4	83%
A0600	47%	21%	7%	75%	66%	83%	_	_	83%
A0273	44%	37%	5%	85%	92%	93%	_	<u> </u>	91%
J0019	45%	30%	11%	85%	100%	93%	_	I	88%
A0307	51%	35%	9%	95%	93%	102%	-	9%	86%
A0585	43%	43%	5%	91%	92%	98%	7%	-	99%
A0672	48%	40%	9%	97%	103%	103%	1 6%		101%
A0439	25%	43%	10%	78%	83%	83%	1 5%	7	83%
A0686	47%	23%	8%	78%	85%	83%	1 5%	-2%	83%
A0365	41%	42%	10%	93%	92%	98%	1 5%	1 6%	86%
F0017	33%	36%	9%	85%	96%	90%	⇒ 5%	-6%	88%
A0474	56%	42%	0%	98%	87%	103%	⇒ 5%	16%	103%
F0022	55%	33%	10%	98%	95%	103%	⇒ 5%	1 8%	98%
A0591	34%	43%	7%	84%	90%	89%	⇒ 5%	-2%	87%
A0206	53%	35%	10%	98%	99%	102%	⇒ 5%	⇒ 3%	85%
F0191	24%	51%	10%	86%	96%	90%	⇒ 5%	-6%	88%
A0410	53%	35%	10%	98%	101%	102%	→ 4%	1%	86%
A0285	49%	39%	10%	98%	96%	103%		6 %	89%
A0696	44%	47%	8%	99%	106%			_	98%
A0696	44%	47%	8%	99%	106%			ž	98%
A0696	44%	47%	8%	99%	106%			ž	98%
A0496	34%	43%	8%	85%	91%				90%
J0014	45%	45%	9%	99%	106%			<u> </u>	88%
A0677	34%	42%	10%	85%	95%	88%		<u> </u>	91%
A0061	24%	48%	13%	85%	96%	88%		<u> </u>	88%
F0003	45%		13%	100%	103%			7	102%
A0624	49%		7%	100%	94%			970	102%
A0335	49%			100%	101%				
			9%		90%				100%
A0669	49%	44%	8%	100%		103% 91%		-	103%
A0609	34%	48%	12%	89%	89%			_	88%
A0689	42%	40%	5%	86%	98%				102%
A0151	47%	26%		81%	67%			_	83%
F0008	33%	33%	10%	101%	101%				88%
A0338	50%		5%	99%	97%				92%
A0497	33%	43%	10%	85%	91%				88%
F0002	30%	45%	8%	101%	105%				97%
F0014	35%	49%	13%	97%	104%				88%
A0545	49%		8%	103%	97%			_	103%
A0691	44%	52%	7%	103%	108%				100%
A0691	44%	52%	7%	103%	108%	103%			100%
A0691	44%	52%	7%	103%	108%	103%	→ 0%	-6%	100%
J0050	45%	44%	11%	100%	101%	100%	→ 0%	-1%	90%

Tabela 4.2 – Resultados de GDO 2016 (variação positiva entre GDO 2015 e GDO 2015 Previsto)

ID	OBJ FIN	OBJ INDV	OBJ COMPT	GDO	GDO Médio	GDO 2015	Δ	Δ	GDO 2016
COLAB -	2015	2015	2015	2015				Prev15-Média2015	previsto 🔻
F0016	30%	45%	10%	101%	100%	101%			88%
A0464	12%	59%	13%	83%	70%	83%		13%	85%
F0001	44%	39%	13%	96%	97%	96%		_	88%
A0073	47%	38%	7%	92%	96%	92%	J 0%	-4%	84%
F0015	55%	38%	10%	103%	95%	102%	J 0%	7%	101%
A0675	50%	30%	5%	85%	99%	84%	-1%	-15%	83%
A0717	24%	50%	10%	85%	84%	84%	-1%	→ 1%	86%
A0684	44%	51%	9%	104%	106%	103%	-1%	-3%	102%
A0442	49%	44%	10%	103%	101%	102%		II. The state of t	96%
F0010	55%	23%	13%	91%	90%	90%	-1%	4 0%	88%
A0573	44%	45%	10%	99%	98%	98%		J 0%	103%
A0240	30%	50%	10%	89%	80%	88%		1 8%	88%
A0082	50%	45%	5%	99%	96%	98%			92%
A0695	42%	53%	10%	104%	101%	102%		→ 1%	88%
A0695	42%	53%	10%	104%	101%	102%			88%
A0695	42%	53%	10%	104%	101%	102%		→ 1%	88%
A0680	42%	54%	9%	105%	101%	103%			88%
A0599	47%	38%	9%	93%	80%	91%		11%	85%
A0532	31%	50%	10%	90%	79%	88%		1 9%	88%
A0194	38%	56%	10%	104%	101%	102%		l '	88%
A0312	49%	46%	10%	105%	102%	102%			95%
F0007	56%	42%	8%	105%	102%	102%	-3%	4 0%	103%
F0018	30%	43%	10%	101%	99%	98%		*	87%
J0048	58%	40%	5%	103%	76%	100%	T		83%
A0693	41%	40%	8%	88%	97%	85%		1 7	83%
A0693	41%	40%	8%	88%	97%	85%		1 7	83%
A0693	41%	40%	8%	88%	97%	85%	T	Y	83%
A0693	41%	40%	8%	88%	97%	85%		1	83%
A0693	41%	40%	8%	88%	97%	85%		-12%	83%
A0421	41%	55%	10%	106%	99%	102%	T		102%
A0688	42%	43%	13%	98%	97%	94%		Y	89%
F0012	55%	38%	10%	102%	101%	98%		1 7	98%
A0277	49%	46%	10%	105%	104%	101%	T	*	97%
A0324	55%	43%	9%	107%	100%	103%		,	95%
A0557	36%	47%	10%	92%	93%	88%		1 <u>1</u>	88%
A0651	36%	47%	10%	92%	88%	88%		*	88%
A0529	49%	50%	8%	107%	103%	103%		*	102%
F0004	55%		10%			103%			102%
A0469	33%		10%	88%	93%	83%		1	98%
F0019	56%		9%	108%	104%	103%			103%
A0586	36%	48%	10%	93%	96%	88%			88%
A0523	34%	49%	12%	94%	91%	88%		1	100%
A0347	46%	51%	11%	108%	105%	102%		1 -	90%
A0475	31%		13%	95%	88%	88%		· ·	88%
A0196	57%		13%	90%	88%	83%			83%
A0491	51%	49%	8%	108%	96%	102%	- 7%	5%	102%

Tabela 4.3 – Resultados de GDO 2016 (variação negativa entre GDO 2015 e GDO 2015 Previsto até -7% de diferença)

ID	OBJ FIN	OBJ INDV	ОВЈ СОМРТ	GDO	GDO Médio	GDO 2015	Δ		Δ		GDO 2016
COLAB -	2015	2015		2015	2012-2015			15-2015 🕶		v15-Média2015 ▼	previsto 🔻
A0047	51%	30%	9%	90%	91%	83%	1	-7%	1	-8%	83%
A0712	41%	45%	10%	96%	92%	89%	1	-7%	1	-3%	94%
A0336	49%	52%	9%	110%	104%	102%	1	-7%	Ţ	-1%	101%
F0011	55%	42%	10%	107%	100%	100%	1	-7%	Ţ	0%	102%
A0682	47%	56%	8%	110%	105%	103%	1	-8%	Ţ	-2%	103%
A0114	36%	50%	10%	96%	91%	88%	1	-8%	1	-3%	88%
J0054	45%	54%	13%	112%	112%	103%	1	-9%	1	-9%	89%
A0613	49%	59%	1%	109%	92%	99%	1	-9%	1	8%	91%
A0502	29%	59%	10%	97%	94%	88%	1	-9%	1	-6%	88%
A0164	50%	38%	5%	93%	88%	83%	1	-10%	₽.	-5%	85%
J0047	45%	55%	13%	113%	112%	103%	1	-10%	1	-9%	88%
A0687	30%	59%	10%	98%	94%	88%	1	-10%	1	-7%	88%
A0606	42%	47%	10%	98%	86%	88%	1	-10%	\Rightarrow	2%	88%
A0605	54%	35%	10%	99%	87%	88%	1	-11%	\Rightarrow	1%	88%
J0041	58%	42%	10%	100%	82%	88%	1	-12%	1	6%	83%
A0333	55%	37%	10%	102%	97%	89%	1	-12%		-7%	103%
A0330	46%	43%	11%	100%	91%	88%	1	-13%	1	-4%	96%
A0207	53%	41%	10%	104%	101%	91%	1	-13%	1	-10%	88%
A0592	41%	52%	9%	101%	100%	88%	1	-13%	₽.	-12%	88%
A0567	38%	51%	12%	101%	94%	88%	1	-13%	1	-6%	88%
A0679	48%	59%	11%	117%	103%	103%	1	-15%	1	-1%	96%
A0094	46%	55%	11%	112%	101%	96%	1	-16%	1	-5%	88%
A0086	55%	54%	10%	119%	107%	101%	1	-18%	1	-5%	88%
A0531	57%	52%	11%	120%	106%	101%	1	-19%	1	-5%	102%
A0690	48%	54%	12%	114%	102%	91%	1	-23%	Φ	-11%	103%

Tabela 4.4 – Resultados de GDO 2016 (variação negativa entre GDO 2015 e GDO 2015 Previsto superior a -7% de diferença)

Destas tabelas constata-se que sempre que os valores reais do GDO 2015 face à média do GDO2012-2015 apresenta diferenças significativas, constata-se que o modelo tem grandes dificuldades em prever os valores estimados para 2015 e 2016.

Agregando a totalidade dos resultados apresentados nas tabelas 4.2, 4.3 e 4.4, pode-se analisar o resultado global ao nível da sua dispersão através do gráfico radar apresentado na figura 4.1.




Figura 4.1 – Visualização dos valores do GDO 2015, GDO 2015 Previsto e GDO 2016 Previsto

Procurando identificar outras razões que levam à disparidade de resultados para além pelo erro que caracteriza o modelo, analisaram-se em particular as observações com diferenças superiores a 10%.

Com variações positivas superiores a 10% encontram-se 7 colaboradores internos de Equipas de Negócio identificadas com a Letra A, cujos resultados do GDO 2015 foram bastante baixos (variação de valores entre 49% e 88%). Para estes casos concretos, a tendência do modelo em produzir valores de GDO 201 para resultados mais próximos dos valores esperados de desempenho poderá explicar estas variações positivas significativas.

Para variações negativas superiores a 10% identificaram-se 29 colaboradores internos distribuídos por 3 Equipas de diferentes características cuja distribuição está espelhada na tabela 4.5:

Identificação das Equipas	Δ GDO 2016-2015 ≤-10%
Letra J	71%
Letra A	21%
Letra F	17%

Tabela 4.5 – Distribuição dos resultados de GDO com diferenças negativas superiores a 10% pelas diferentes Equipas da Organização

Os colaboradores internos identificados com a Letra J pertencem a Equipas cujo modelo de negócio é significativamente diferente dos restantes existentes na Organização e representam uma minoria em termos de representatividade. A deficiente capacidade preditiva do modelo poderá ser justificada pela existência deste *cluster* ao nível da tipologia de negócio na Organização. Analisando detalhadamente as observações identificadas, constata-se que os resultados de GDO no período 2012-2015 apresentam flutuações positivas e negativas bastante significativas não contribuindo positivamente para a construção de um modelo que represente com eficácia o desempenho destes colaboradores internos.

Os colaboradores internos identificados pela Letra A pertencem a Equipa de Negócio. Analisando o histórico das avaliações de desempenho obtidas no período 2012-2015, constata-se que genericamente, obtiveram valores de GDO uniformes no período 2012-2014 e em 2015 obtiveram uma avaliação consideravelmente diferente. Esta situação contribui negativamente para a qualidade preditiva do modelo selecionado.

Já os colaboradores internos identificados pela Letra F representam Equipas de Suporte, cujos resultados na componente financeira devem traduzir os resultados da Organização pela especificidade das suas funções. Desde o início do Trabalho de Projeto que era expectável que os resultados previstos para o GDO 2016 tivessem valores atípicos. Ainda assim, em 18 colaboradores internos, apenas 3 apresentam evoluções com diferenças significativas (-13% e – 14%) face ao GDO 2015.

4.1.2. Previsão dos resultados do Talent Review 2016

A Base de Dados disponibilizada pela Organização com os resultados do processo *Talent Review* 2015 continha inicialmente 273 observações. Apesar deste número, apenas 92 observações (colaboradores internos) foram incluídos do processo de previsão da classificação de Talentos de 2016, resultantes do *mach* entre colaboradores do *dataset Talent Review* 2015 e do *dataset* GDO 2016 (figura 4.2).

Nr de observações

(colaboradores internos)




Figura 4.2 Observações do Trabalho de Projecto

Esta redução do número de observações resultou numa perda de representatividade dos colaboradores internos e das suas classificações ao nível dos Taletos. Em particular, apenas 28% dos colaboradores identificados pela Organização como *High Potentials* em 2015 estão representados no *dataset Talent Review* 2016.

Pela caracterização anterior do processo *Talent Review* e da análise dos resultados de 2015, existia desde o início do Trabalho de Projeto, a consciência de uma previsão deficiente das classificações em 2016 pela dificuldade de identificação de padrões de comportamento na amostra. Apresentando apenas a análise efetuada aos colaboradores internos *High Potentials*, e recordando que a contribuição financeira/business results é um dos 2 fatores para a obtenção da classificação dos Talentos no modelo utilizado pela Organização, encontram-se praticamente todos os valores possíveis a atribuir a esta variável na classificação em análise conforme se apresenta na figura 4.3:




Figura 4.3 – Distribuição dos Colaboradores High Potentials pelas várias Equipas

Para validar os dados de *input* da Organização, foi realizada previamente a previsão das classificações dos colaboradores em 2015 utilizando os valores reais do processo GDO 2015 para comparação com as classificações do *Talent Review* 2015 da Organização.

De seguida, foram então apurados os valores previstos para o *Talent Review* 2016 utilizando os critérios da nova Matriz de Talentos apresentada no capítulo 3.6.

Os diversos resultados obtidos encontram-se espelhados na figura 4.4.




Figura 4.4 – Distribuição das classificações de Talentos 2015-2016

Pela análise deste gráfico constata-se uma disparidade significativa das novas classificações de Talentos face às classificações de 2015; no entanto, aplicando a mesma abordagem aos dados, ou seja, utilizando os resultados do processo GDO, essa diferença fica esbatida.

A qualidade dos resultados obtidos neste Trabalho de Projeto permite, de forma bastante limitada, identificar novas classificações de Talentos. Para inverter esta situação, serão apresentadas no capítulo seguinte, um conjunto de sugestões que visam incidir sobre cada uma das causas das limitações apontadas na utilização do *Peolple Analytics* na Organização identificadas ao longo deste Trabalho de Projeto.

5. CONCLUSÕES

Este Trabalho de Projeto descreve o enquadramento do *People Analytics* nas organizações como ferramenta da função Recursos Humanos para apoiar os CEO's na tomada de decisões estratégicas. O *focus* incidiu sobre a Retenção de Talentos pelo reconhecimento da importância em contar com as melhores pessoas no crescimento sustentado da Organização onde o Trabalho de Projeto foi desenvolvido. A identificação atempada dos seus Talentos é um objetivo da Organização para definição das estratégias eficazes à sua retenção, pelo que, este Trabalho de Projeto visou prever as classificações de Talento utilizadas na mesma através da aplicação dos métodos considerados mais adequados.

Este tema foi apresentado por diversas vezes como um desafio para os Recursos Humanos cuja implementação é amplamente recomendada, ainda que esteja numa fase muito precoce na maioria das organizações. Para melhor compreender o tema da Retenção de Talentos foi proposto conhecerse a literatura aplicável que permitisse caracterizar os Talentos das organizações.

Na fase da retenção, a caracterização do Talento é composta por diversos atributos sugeridos por vários autores. Estes podem ser agregados em 3 componentes distintas: atributos relativos ao background do indivíduo, avaliação de desempenho e características individuais.

A identificação das técnicas adequadas para exploração de dados e previsão na área da Retenção de Talentos, apontou para a utilização das Árvores de Decisão e Redes Neuronais no domínio do *Data Mining*. Sendo estas técnicas específicas de abordagem aos dados do tipo *data driven* para implementação do conceito *machine learning*, é essencial obter uma base de dados com padrões de comportamento em quantidade e qualidade para obtenção de modelos preditivos robustos.

A obtenção do modelo preditivo através das técnicas de *Data Mining* selecionadas assenta na utilização de valores históricos. Para tal, foi identificada a componente avaliação de desempenho sugerida pela literatura aplicável à caracterização do Talento como a que serviria este propósito por existência dos dados necessários na Organização.

A constituição da base de dados com a informação sobre a avaliação de desempenho com o objetivo de prever os resultados no período seguinte, recorrendo às etapas de preparação e préprocessamento dos mesmos visando a sua qualidade, resultou na obtenção de um número reduzido de observações consideradas válidas. Esta situação condicionou a precisão do modelo preditivo obtido revelando-se pouco eficaz na previsão das novas avaliações de desempenho dos colaboradores internos da Organização.

A estratégia adotada na metodologia deste Trabalho de Projeto para a obtenção das novas classificações de Talento na Organização assumiu a manutenção das características individuais dos colaboradores internas da Organização e, face aos valores da avaliação de desempenho previstos, foi criada uma nova Matriz de Talentos.

A aplicação de forma díspar das regras definidas para o processo de classificação de Talentos pela Organização, dificulta a replicação do processo incompatibilizando-se com a utilização de modelos matemáticos com regras claramente definidas. Assim, as classificações previstas da aplicação da Matriz de Talentos concebida neste Trabalho de Projeto, não permitem colaborar de forma

totalmente eficaz com a Organização na identificação da sua Bolsa de Talentos para posterior aplicação de estratégias de retenção atempadas.

A eficácia em alcançar os objetivos propostos para este Trabalho de Projeto foi condicionada pelas várias limitações que foram sendo apontadas ao longo da constituição dos processos descritivos e preditivos, assim como, pela diversidade da caracterização das várias Equipas da Organização e da dinâmica inerente ao negócio. A introdução de algumas das seguintes sugestões poderão no futuro permitir à Organização melhorar a eficácia da análise dos seus dados e prever novos resultados com maior qualidade.

Sugestão 1 – Para melhorar o preenchimento de cada uma das colunas da base de dados do *Talent Review*, recomenda-se a criação de uma manual com instruções detalhadas para adequação das especificidades das características da Organização.

Sugestão 2 — Sugere-se o abandono do processo manual do *Talent Review* e iniciar-se o desenvolvimento de uma aplicação interna para automatizar o processo, interligado com o processo do GDO (processo implementado através de aplicação informática) e prevendo um conjunto de regras de preenchimento pré-definidas:

- Os campos de identificação do colaborador estariam automaticamente preenchidos e com dados de background corretos e completos;
- A avaliação do colaborador interno ficaria parametrizada de acordo com o seu procedimento específico, permitindo um processo de recolha centralizada com regras de validação e alertas para apoio à chefia.

Sugestão 3 – Os resultados das variáveis *Judgement*, *Drive* e *Influence* poderão ser obtidos com base na avaliação das várias componentes que constituem estes conceitos. Esta sugestão enquadra-se no objetivo de apoiar a chefia a realizar uma avaliação mais rigorosa e menos subjetiva.

Sugestão 4 – Recomenda-se ainda a revisão da periodicidade do processo interno de *Talent Review* na Organização. A existência de avaliações faseadas, ao trimestre ou quadrimestre por exemplo, permitirá a obtenção dos resultados anuais com maior rigor e transparência.

As análises, resultados e conclusões apresentadas resultam do enquadramento da organização no momento da recolha dos dados de *inputs* e processos em vigor. Deverão ser enquadradas e adequadas no futuro, sempre que a Organização adote novos comportamentos, nomeadamente:

- Tomada de decisões estratégicas com impacto no negócio;
- Possíveis alterações dos processos do Talent Review/GDO;
- Tomada de decisões estratégicas na estrutura organizacional.

Como conclusão final, a capacidade de compreensão dos dados e do conhecimento que deles advém para criar as condições para uma adequada previsão na área da Retenção de Talentos é possível de realizar e necessária para o novo posicionamento da função Recursos Humanos. Requer, no entanto, uma abordagem sistematizada aos dados e aos processos e adoção de novas ferramentas analíticas

que tornem robusto o seu papel. A utilização de forma sistemática do *Peolpe Analytics* como uma ferramenta da função Recursos Humanos permitirá contribuir de forma eficaz para a definição de estratégias tanto ao nível da Retenção de Talentos, como noutras áreas no domínio da gestão de recursos humanos.

6. LIMITAÇÕES E RECOMENDAÇÕES PARA TRABALHOS FUTUROS

O Trabalho de Projeto desenvolvido baseou-se no estudo de uma amostra cuja população é heterogénea, assente em dados históricos num curto período temporal e utilizando uma variável target contínua. Acresce a esta caracterização, a utilização de uma base de dados com poucas observações para aplicação de técnicas de *Data Mining* baseadas em data driven e machine learning, relevantes na aplicação de Árvores de Decisão e Redes Neuronais.

Estudos com metodologia e objetivos equivalentes utilizando variáveis *target* de classe, apresentam bons resultados da *accuracy* dos modelos resultantes.

Assim, para trabalhos futuros é recomendável a exploração de base de dados de Recursos Humanos relativos à Retenção de Talentos fazendo diferentes abordagens:

- Utilização de outras técnicas de abordagem aos dados para além das Árvores de Decisão e Redes Neuronais; variações da Regressão poderão obter dados com uma accuracy equivalente ou superior;
- Criação de variáveis target do tipo classe para avaliação do comportamento dos modelos por comparação a modelos com variáveis target contínuas;
- Utilização de observações baseadas em amostras homogéneas para melhorar e aumentar o número de padrões de comportamento a suportar o modelo de previsão.

7. BIBLIOGRAFIA

- Ariss, A. A. (2014). Global Talent Management Challenges, Strategies, and Opportunities. (A. A. Ariss, Ed.) Toulouse Business School, Université de Toulouse: Springer International Publishing.
- Bação, F. (2013). Introdução ao Data Mining, Apontamentos Mestrado. Lisboa: NOVA IMS.
- BCG. (2014). Creating People Advantage 2014-2015, How to set up great HR Functions: Connect, Prioritize, Impact (8th Ed.). Boston: BCG. Obtido de https://www.peryon.org.tr/wp-content/uploads/arastirma raporlari/BCG Creating People Advantage 201 2015.pdf
- Ben-Shahar, T. (Fevereiro de 2015). A felicidade paga-se a si própria. *Revista Human, Recursos Humanis e Gestão, número 74*, p. 12.
- Berry, M., & Linoff, G. (2004). *Data mining techniques for marketing, sales, and customer relationship management, 2nd Edition.* Wiley Publishing, Inc.
- D'Amato, A., & Herzfeldt, R. (2008). Learning orientation, organizational commitment and talent retention across generations: A study of European managers. *Journal of Managerial Psychology, 23, No 8*, 929-953.
- Davenport, T., Harris, J., & Shapiro, J. (Outubro de 2010). *Competing on Talent Analytics*. Obtido de Harvards Business Review: https://hbr.org/2010/10/competing-on-talent-analytics
- Deloitte. (2015). Global Human Capital Trends 2015, Leading in the new world of work. Press,
 Deloitte University. Obtido de http://www2.deloitte.com/us/en/pages/humancapital/articles/introduction-human-capital-trends.html
- Fernândez-Aráoz, C. (Junho de 2014). Hire for Potential, Not Just Experience. (H. B. Review, Entrevistador) Obtido de https://hbr.org/video/3603876266001/hire-for-potential-not-just-experience
- Fernández-Aráoz, C., Groysberg, B., & Nohria, N. (Outubro de 2011). How to Hang On to Your High Potentials. *Revista Harvard Business Review*, pp. 78-81.
- Fitz-enz, J., & MattoxII, J. R. (2014). *Predictive Analytics for Human Resources*. Hoboken, New Jersey: John Wiley & Sons, Inc.
- Gardner, N., McGranahan, D., & Wolf, W. (Março de 2011). Question for your HR chief: Are we using our 'people data' to create value?". Obtido de mackinsey:

 http://www.mckinsey.com/insights/organization/question_for_your_hr_chief_are_we_using _our_people_data_to_create_value
- Hand, D. J. (1998). Data mining: statistics and more? The American Statistician, 52 (2), 112-118. doi:10.1080/00031305.1998.10480549

- Jantan, H., Hamdan, A., & Othman, Z. (2009). Knowledge Discovery Techniques for Talent Forecasting in Human Resource Application. *World Academy of Science, Engineering and Technology, 03*, 579-587. Obtido de http://waset.org/publication/Knowledge-Discovery-Techniques-for-Talent-Forecasting-in-Human-Resource-Application/11782
- Jantan, H., Hamdan, A., & Othman, Z. (2010). Classification and Prediction of Academic Talent Using Data Mining Techniques. Em *Knowledge-Based and Intelligent Information and Engineering Systems* (Vol. 6276, pp. 491-500). Springer-Verlag Berlin Heidelberg. doi:3-642-15386-0 978-3-642-15386-0
- Jantan, H., Hamdan, A., & Othman, Z. (2010). Data Mining Classification Techniques for Human Talent Forecasting. Em *Knowledge-Oriented Applications in Data Mining* (pp. 1-14). Funatsu, Prof. Kimito. Obtido de InTech: http://www.intechopen.com/books/knowledge-orientedapplications-in-data-mining/data-mining-classification-techniques-for-human-talent-forecasting
- Jantan, H., Hamdan, A., & Othman, Z. (2010). Human Talent Prediction in HRM using C4.5 Classification Algorithm. *International Journal on Computer Science and Engineering, 02, No. 08*, 2526-2534. Obtido de http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.301.6048&rep=rep1&type=pdf
- Mitchell, T., Holtom, B., & Lee, T. (Novembro de 2001). How to keep your best employees:

 Developing an effective retention policy. *The Academy of Management Executive, 15, Número 4*, 96-109. Obtido de

 http://www.csus.edu/indiv/s/sablynskic/documents/Keepingyourbest.pdf
- Pease, G., Byerly, B., & Fitz-enz, J. (2013). *Human Capital Analytics How to Harness the Potential of Your Organization's Greatest Asset.* Hoboken, New Jersey: John Wiley & Sons, Inc.
- Pereira, I. V. (Fevereiro de 2015). Diferentes perspectivas na gestão do talento. *Revista Human, Recursos Humanis e Gestão, número 74*, pp. 18-22.
- PriceWaterhouseCoopers. (2015). *Trends in People Analytics Report*. Obtido de http://www.pwc.com/us/en/hr-management/publications/trends-workforce-people-analytics.html
- Ready, D., Conger, J., & Linda, H. (Junho de 2010). *Are You a High Potential?* Obtido de https://hbr.org/2010/06/are-you-a-high-potential
- Sadath, L. (Abril de 2013). Data Mining: A Tool for Knowledge Management in Human Resource. 02(6), pp. 154-159. Obtido de http://www.ijitee.org/attachments/File/v2i5/E0702042413.pdf
- Troni, N. (Outubro de 2015). Como atrair e manter a geração "Millenial" nas empresas. *Jornal de Negócios.pt*. Obtido de http://www.jornaldenegocios.pt/empresas/pme/gestao_e_gestores/detalhe/como_atrair_e __manter_a_geracao_millennial_nas_empresas.html

- Watson, T. (2014). Global Talent Management and Rewards Study, At a Glance. Obtido de https://www.towerswatson.com/en/Insights/IC-Types/Survey-Research-Results/2014/08/2014-global-talent-management-and-rewards-study-making-the-most-of-employment-deal
- Welch, J. (2007). Recrutamento, De que são feitos os Vencedores. Em J. Welch, *Vencer* (pp. 83-98). Conjuntura Actual Editora, Lda.
- YSC. (2015). High Potential identification & Development: The JDI Model. Obtido de http://www.ysc.com/what-we-do/talent/high-potential-identification-development-the-jdi-model

8. ANEXO

8.1. DIAGRAMA CRIADO NA APLICAÇÃO SAS MINER 9.3 PARA MODELAÇÃO PREDITIVA DO GDO




Figura 8.1 – Diagrama criado na aplicação SAS Miner 9.3 para modelação preditiva do GDO